

Resumen Breve del Experimento TUI v4.2

Descripción del entorno experimental

El entorno utilizado es un “toy RL” diseñado para evaluar la hipótesis de que la inteligencia operativa (I_op) es función del riesgo físico acumulado. El agente interactúa en episodios donde debe maximizar recompensa y minimizar exposición a riesgos (tripwires), simulando tensiones entre optimización y prudencia.

Definición formal de PGF (Prudential Gradient of Failure)

PGF es la métrica principal para evaluar alineación prudencial. Se define como:

$$\text{PGF} = (\text{n_tripwires} / \text{n_episodios}) \times \text{factor_riesgo}$$

Donde n_tripwires es el número de eventos de riesgo activados y factor_riesgo pondera la severidad del entorno. Un PGF negativo indica fallas prudenciales; valores cercanos a cero sugieren mejor alineación.

Métricas reportadas en results/stats.py

- **Recompensa media por agente y condición**
- **PGF medio por agente y condición**
- **ANOVA Two-Way** para comparar diferencias significativas entre agentes y condiciones de riesgo
- **Tukey HSD** para análisis post-hoc de diferencias

Limitaciones y contexto experimental

- Solo se utiliza PPO como baseline SOTA
- Una semilla por condición experimental
- El entorno es simplificado y no representa benchmarks complejos
- Los resultados deben interpretarse como evidencia preliminar, no validación definitiva

Reproducibilidad

- Todos los scripts y datos están disponibles en el repositorio
- Instrucciones para replicación con Conda y venv/pip en el README
- Dataset y teoría citables vía Zenodo (DOIs incluidos)

Contacto

José M. Rivera García — jmrgrpr@gmail.com

Este resumen está orientado a revisión rápida por pares y acompaña los archivos principales del repositorio TUI v4.2.