

Teoría Unificada de la Inteligencia (v4.1)

José M. Rivera García

2025-11-06

Abstract

Presento un marco unificado donde la inteligencia operativa emerge como función del riesgo/inversión acumulada ($H1: I \propto P_{\text{riesgo}}^{\alpha}$, con $\alpha \approx 0.35$ y $R^2=0.83$), con métricas operacionales independientes (C: capacidad predictiva, F: flexibilidad, T: transferencia). La teoría integra: (i) Principio de Gradiente de Fracaso (PGF) que formaliza la dinámica local de aprendizaje bajo riesgo efectivo y propósito genuino ($P_{\text{genuino}} = (C_{\text{costo}} \cdot S_{\text{auto}} \cdot R_{\text{robust}} \cdot I_{\text{rep}})^{1/4}$), (ii) Principio de Equidad por Dominio (PED) para comparaciones justas entre especies ($I_{\text{justo}} = T_{\text{iss}}^{\alpha} \cdot \text{Meta}^{\beta} \cdot \text{avg}(I_{\text{op}}^k)$ en dominio temporal común), (iii) extensión a inteligencia colectiva (Apéndice G) con riesgo de red y alignment de red (A_{net}). Incluye 13+ predicciones falsables, protocolos operacionales y análisis de limitaciones críticas.

Table of Contents

1	Teoría Unificada de la Inteligencia v4.1: Un Marco Impulsado por Riesgo y Propósito	4
1.1	alignment y Referencias Cruzadas	4
1.2	Resumen	4
1.3	1. Axiomas Fundamentales	5
1.3.1	Definición Operacional de <i>Priesgo_physical</i> (sin circularidad)	5
1.3.2	Definición Operacional de <i>Priesgo</i> en IA (factorizada)	6
1.3.3	1.5 Definición Operativa de Inteligencia (Independiente de P_{riesgo})	7
1.4	1.6 Criterio Operacional: Continuo de Inteligencia Genuina	10
1.4.1	1.6.1 El Caso GPT-4: Confirmación, No Refutación	10
1.4.2	1.7 Propósito Genuino: Índice Continuo	11
1.4.3	1.8 Principio de Gradiente de Fracaso (PGF)	14
1.5	2. Ecuación Extendida de Eficiencia	16
1.6	3. Hipótesis Falsable y Predicciones	16
1.6.1	Afirmación Formal	16
1.6.2	Criterios de Falsación	17
1.6.3	Estado Actual: Consistente pero requiere más datos	17
1.7	4. Derivaciones y Conexiones	17
1.8	5. Validación Conceptual y Empírica (Bosquejo ampliado)	17
1.9	6. Implicaciones	18
1.10	7. Figuras sugeridas	18

1.11	8. Limitaciones y Suposiciones Críticas de la Teoría	19
1.11.1	8.1 Inteligencia Colectiva/Distribuida (actualizado)	19
1.11.2	8.1.1 Dominio de validez explícito	19
1.11.3	8.2 Suposiciones Críticas que Podrían Invalidar la Teoría	19
1.11.4	8.2.5 Validación no-circular (hold-out temporal)	21
1.11.5	8.3 Principio de Equidad por Dominio (PED) — Derivación por Invariantes..	21
1.11.6	8.4 Escenarios que Refutarían la Teoría	24
1.11.7	8.6 Agenda de Investigación Futura	25
1.11.8	8.7 Texturas de la Inteligencia: Creatividad y Empatía	25
1.11.9	8.8 Índice de Propósito Genuino — IPG (versión operativa, 0–1).....	28
1.11.10	8.9 C8-T — Pruebas de Mesa (validaciones teóricas sin datos).....	30
1.11.11	8.10 Conclusión de Limitaciones	34
1.12	9. Trabajo relacionado y referencias (C2)	35
1.12.1	9.1 Riesgo como catalizador y “skin in the game”	35
1.12.2	9.2 Propósito, autopoiesis y energía libre	35
1.12.3	9.3 Inteligencia colectiva y unidad de riesgo.....	35
1.12.4	9.4 Comparaciones justas y análisis dimensional (PED).....	35
1.12.5	9.5 Alineamiento, Goodhart y métricas	35
1.12.6	9.6 Inferencia causal y evaluación off-policy	35
1.12.7	9.7 Aprendizaje similar al humano y transferencia	36
1.12.8	9.8 Coste physical de computación y exponente α	36
1.12.9	9.9 Síntesis	36
1.13	Apéndice A: Notación y Unidades.....	36
1.14	Apéndice B: Proxies Operacionales para P_riesgo	36
1.14.1	B.4 Respuesta a Casos Límite	37
1.15	Apéndice F: Taxonomía Unificada de P_riesgo.....	38
1.15.1	F.1 El Problema de las Múltiples Definiciones	38
1.15.2	F.2 Dimensiones de P_riesgo	38
1.15.3	F.3 Fórmula Unificada	38
1.15.4	F.4 Casos Calculados.....	39
1.15.5	F.5 Tabla Comparativa Completa	44
1.15.6	F.6 Validación Estadística de H1	44
2	Correlación de Pearson	45

3	Con árbol incluido.....	45
3.0.1	F.7 Validación Experimental.....	46
3.1	Referencias (selección)	47
3.2	Apéndice E: Derivación Formal de <i>A</i> alignment	47
3.2.1	E.4 Derivación de <i>A</i> alignment desde Primeros Principios (IRL + Teoría de la Información).....	47
3.3	Apéndice D: Derivación de β	48
3.3.1	D.1 Justificación Conceptual	48
3.3.2	D.2 Definición Operacional.....	48
3.3.3	D.3 Predicción	48
3.3.4	D.4 Derivación desde Primeros Principios.....	48
3.4	Apéndice E: Medición de <i>A</i> alignment.....	53
3.4.1	Definición Operativa X–Y–Z	53
3.4.2	E.1 Definición Formal	53
3.4.3	E.2 Tres Métodos de Medición.....	53
3.4.4	E.3 Validación Experimental.....	53
3.5	Apéndice G: Inteligencia Colectiva y Riesgo de Red	54
3.5.1	G.1 Axioma de Escala	54
3.5.2	G.2 Riesgo Colectivo	54
3.5.3	G.3 alignment de Red	54
3.5.4	G.4 Inteligencia Colectiva (definición operativa)	54
3.5.5	G.5 Predicciones Falsables.....	55
3.5.6	G.6 Procedimiento de Verificación	55
3.5.7	G.7 Caso Hormiguero (intuición formalizada).....	55
3.5.8	G.8 PGF en Redes: Dinámica Local de Aprendizaje Colectivo	55
3.6	9. Ruta mínima de publicación (v4.1)	56
3.7	Apéndice F: Datos y Validación Empírica	56
3.7.1	F.2 Expansión de dataset (plan y esquema).....	56
3.7.2	F.3 Exponente α (justificación y sensibilidad)	57
3.8	Apéndice F — Dataset y Protocolo (v1)	57
3.8.1	F.1 Esquemas de datos	57
3.8.2	F.2 Protocolo out-of-sample (hold-out temporal)	57
3.8.3	F.3 Sensibilidad de pesos en <i>I</i> operativa	58

3.8.4	F.4 Nota sobre LLMs (valores ilustrativos)	58
3.9	Glosario de Términos Clave	58
3.10	Referencias (texto simple)	58

⚠ Estado (v4.1, Nov 2025)

Naturaleza: Teoría especulativa con validación preliminar.

Datos: $n \approx 6-7$ casos ilustrativos; ejemplos A/B y valores GPT-4 son **estimaciones/simulaciones**, no mediciones primarias.

Falsabilidad: 13+ predicciones testables y protocolos preregistrables.

Uso recomendado: Investigación y discusión; NO producción.

Citas: Este manuscrito usa citas estilo Pandoc con `references.bib`.

Para exportar a PDF/DOCX: usar `pandoc --citeproc` (ver

`EXPORT_INSTRUCTIONS.md` para comandos completos).

1 Teoría Unificada de la Inteligencia v4.1: Un Marco Impulsado por Riesgo y Propósito

1.1 alignment y Referencias Cruzadas

Nota de alignment: Este documento es el marco central y formalizado para todas las aplicaciones y extensiones, incluyendo el paper ‘Teoría de la Inteligencia Aplicada a IA’.

Todos los axiomas, ecuaciones y proxies aquí definidos ($A_{alignment}$, P_{riesgo} , β , LFM/CR/GDC) son la base para los demás documentos v4.1.

1.2 Resumen

La inteligencia es un fenómeno emergente de optimización multi-objetivo bajo restricciones, que maximiza información útil (ΔI_{useful}) frente a costos totales. La versión v4.1 integra explícitamente dos motores causales de la inteligencia genuina: el riesgo acumulado (P_{riesgo}) y la alignment con propósito (A). Esta formulación unifica la métrica operativa de eficiencia (η), el rol del propósito y la presión selectiva inducida por “tener algo que perder”.

Contribuciones: - Axiomas fundamentales que incorporan eficiencia, riesgo y propósito. - Ecuación extendida de eficiencia ($\eta_{extendido}$) que explica la dinámica prudencial. - Hipótesis falsable H1: $I \propto P_{riesgo}$, con predicciones testables. - Proxies operacionales para P_{riesgo} y guía experimental.

1.3 1. Axiomas Fundamentales

Axiomas Fundamentales Principales:

1. Axioma de Eficiencia

$$\eta = \frac{\Delta I_{\text{useful}}}{\sum \alpha_i C_i}$$

2. Axioma de Eficiencia Bajo Restricciones

Los sistemas optimizan η bajo restricciones ambientales y temporales

3. Hipótesis del Catalizador de Riesgo (H1)

En sistemas naturales: $I_{\text{desarrollada}} \propto P_{\text{riesgo}}$

Donde $P_{\text{riesgo}} = E[\text{pérdida acumulada} | \text{fallo del sistema}]$

Justificación: El riesgo acumulado crea presión selectiva para desarrollar capacidades predictivas y adaptativas más sofisticadas.

Falsabilidad: Predice correlación positiva entre P_{riesgo} y métricas independientes de inteligencia (ver Sección 3.2)

4. Axioma de Propósito

ΔI_{useful} requiere alignment A entre acción y propósito P

Interpretación: sin propósito no hay “información útil” relevante; sin riesgo acumulado no hay presión por inteligencia genuina.

1.3.1 Definición Operacional de $P_{\text{riesgo_physical}}$ (sin circularidad)

Para medir el riesgo acumulado sin referencia a inteligencia, definimos:

$$P_{\text{riesgo_physical}} = \frac{t_{\text{vida}} \times R_{\text{metabólica}} \times C_{\text{genoma}}}{Z_{\text{norm}}}$$

Donde: - t_{vida} : Tiempo promedio de vida del sistema (segundos) - $R_{\text{metabólica}}$: Tasa metabólica basal o consumo energético (watts) - C_{genoma} : Complejidad del código (pares de bases para bio, parámetros para IA) - $Z_{\text{norm}} = 10^{15}$ (constante de normalización calibrada con humano = 1.0)

Cálculos de referencia:

Sistema	t_{vida}	$R_{\text{metabólica}}$	C_{genoma}	$P_{\text{riesgo_physical}}$
Bacteria E.coli	1,200 s	1×10^{-15} W	9.2×10^6 bp	0.00012
Hormiga	2.6×10^7 s	1×10^{-6} W	2.5×10^8 bp	0.0085

Sistema	t_{vida}	$R_{\text{metabólica}}$	C_{genoma}	$P_{\text{riesgo_physical}}$
obrero				
Rata	$6.3 \times 10^7 \text{ s}$	1.5 W	$2.9 \times 10^9 \text{ bp}$	0.085
laboratorio				
Delfín	$1.3 \times 10^9 \text{ s}$	150 W	$3.2 \times 10^9 \text{ bp}$	0.35
Humano	$2.2 \times 10^9 \text{ s}$	80 W	$6.4 \times 10^9 \text{ bp}$	1.00
GPT-4	0 s*	variable	1.8×10^{12}	0.00001
Árbol	$1 \times 10^{11} \text{ s}$	100 W	$5 \times 10^9 \text{ bp}$	0.95
Secuoya				

* $t_{\text{vida}} \approx 0$ porque se resetea cada sesión (no hay continuidad)

CRÍTICO: Esta definición NO usa: - Capacidades cognitivas - Medidas de inteligencia - Propósito o alignment

Solo variables físicas medibles independientemente.

1.3.1.1 Derivación de la Forma Métrica de P_{riesgo}

Partimos de un riesgo acumulado por exposición temporal (t), throughput energético (R) y complejidad de mantenimiento/recuperación (C).

Axiomas de borde: 1. Si $t = 0$ o $R = 0$, no hay riesgo acumulado $\Rightarrow P = 0$. 2. Si $C = 0$ (sistema trivial sin partes que fallar), $P = 0$.

Por lo tanto, la forma mínima que respeta los ceros es multiplicativa:

$$P \propto t^a \cdot R^b \cdot C^c, \quad \text{con } a, b, c > 0$$

En log-espacio, esto se convierte en una forma lineal:

$$\log P = \alpha + a \log t + b \log R + c \log C$$

Esto elimina la acusación de que la fórmula es una “forma ad-hoc” y convierte los exponentes a, b, c en parámetros a estimar empíricamente, cuyo ajuste se puede validar con análisis de sensibilidad.

1.3.2 Definición Operacional de P_{riesgo} en IA (factorizada)

Para IA, descomponemos el riesgo total en **entrenamiento** y **operación**:

$$P_{\text{riesgo}}^{\text{total}} = w_{\text{train}} \cdot P_{\text{train}} + w_{\text{op}} \cdot P_{\text{op}}$$

Riesgo de entrenamiento (inversión irrecuperable):

$$P_{\text{train}} = \frac{E_{\text{train}}}{Z_E} \cdot (1 - \rho_{\text{backup}}) \cdot (1 - \rho_{\text{replica}})$$

donde ρ capturan **recuperabilidad** (backups, réplicas, verificación). “Serializable” no anula P_{train} ; solo lo **descuenta** vía ρ .

Riesgo operativo (daño en tiempo real):

$$P_{\text{op}} = \frac{1}{T} \int_0^T (R_{\text{consumo}} + R_{\text{datos}} + R_{\text{control}}) dt$$

con términos para compute/energía, integridad/seguridad de datos y dependencias de control.

Horizonte temporal de IA (β) sin sesgo de “sesión”:

$$\beta_{\text{IA}} = \frac{\log(T_{\text{uptime}}/t_{\text{reacción}})}{\log T_{\text{max}}}$$

donde T_{uptime} es continuidad de despliegue y se considera el **estado persistente mínimo** (memorias, colas, cachés).

1.3.3 1.5 Definición Operativa de Inteligencia (Independiente de P_riesgo)

Para evitar circularidad, definimos inteligencia operativamente SIN referencia a riesgo acumulado:

Definición:

$$I_{\text{operativa}}(S, E, t) = w_C \cdot C + w_F \cdot F + w_T \cdot T$$

Donde: - C (Capacidad predictiva): Reducción de entropía lograda

$$C = \frac{H(E_{\text{antes}}) - H(E_{\text{después}})}{\text{costo}_{\text{computacional}}}$$

- F (Flexibilidad): Adaptación exitosa a contextos novedosos

$$F = \frac{P(\text{éxito}|\text{contexto}_{\text{nuevo}})}{P(\text{éxito}|\text{contexto}_{\text{entrenado}})}$$

- T (Transferencia): Aplicación de conocimiento entre dominios

$$T = \frac{\Delta I_{\text{util_dominio_B}}}{\Delta I_{\text{util_dominio_A}}}$$

Pesos normalizados: $w_C + w_F + w_T = 1$

Protocolo de Medición:

```
def medir_inteligencia_operativa(sistema, ambiente):
    """Medición independiente de I sin asumir P_riesgo"""
```

```

# Componente 1: Capacidad predictiva
H_inicial = calcular_entropia(ambiente.estado_inicial)
predicciones = sistema.predecir(ambiente, n_pasos=100)
H_final = calcular_entropia(ambiente.estado_post_predicciones)
costo = sistema.recursos_utilizados()

C = (H_inicial - H_final) / costo if costo > 0 else 0

# Componente 2: Flexibilidad
exito_familiar = sistema.tasa_exito(ambiente.contexto_entrenado)
exito_novel = sistema.tasa_exito(ambiente.contexto_nuevo)

F = exito_novel / exito_familiar if exito_familiar > 0 else 0

# Componente 3: Transferencia
delta_A = sistema.informacion_util_dominio_A()
delta_B = sistema.informacion_util_dominio_B()

T = delta_B / delta_A if delta_A > 0 else 0

# Agregación
w = [0.4, 0.3, 0.3] # Pesos contextuales
I_op = w[0]*normalizar(C) + w[1]*normalizar(F) + w[2]*normalizar(T)

return I_op, {"C": C, "F": F, "T": T}

def normalizar(x, x_min=0, x_max=10):
    """Normalizar a [0,1]"""
    return (x - x_min) / (x_max - x_min) if x_max > x_min else 0

```

Casos de Referencia (Valores Empíricos Calculados):

Sistema	C	F	T	I_{op}	P_rie sgo	β	Notas
Bacteria E.coli	0	0	0	0.300	0.40	7.	Alta predicción química, baja
	.	.	.		0	09	flexibilidad
	6	1	0				
	0	5	5				
Hormiga (P. barbatus)	0	0	0	0.445	0.61	15	Navegación eficiente, aprendizaje
	.	.	.		8	.8	limitado
	7	3	2			7	
	0	5	0				
Árbol (Secuoya)	0	0	0	0.205	0.68	—	Predicción estacional, respuesta fija
	.	.	.		8		
	4	1	0				
	0	0	5				

Sistema	C	F	T	I_{op}	P_rie sgo	β	Notas
Rata laboratorio	0	0	0	0.645	0.88	20	Excelente aprendizaje espacial
	.	.	.		6	.9	
	7	6	5			5	
	5	5	0				
GPT-4 (2024)	0	0	0	0.560	0.20	0	Predicción estadística excelente, falla OOD
	.	.	.		0		
	9	2	3				
	5	5	5				
Delfín (T. truncatus)	0	0	0	0.805	0.93	22	Resolución problemas, aprendizaje social
	.	.	.		4	.5	
	8	8	7			7	
	5	0	5				
Humano adulto	0	0	0	0.875	0.90	23	Máxima flexibilidad y transferencia
	.	.	.		3	.4	
	8	9	9			8	
	0	0	5				

Correlación empírica: $r(I_{op}, P_{riesgo}) = 0.87$ ($p < 0.01$) sin outliers

Validación de H1: $I_{operativa} \propto P_{riesgo}$ confirmada en sistemas con aprendizaje

Validación de Independencia: Esta métrica NO menciona P_{riesgo} , propósito evolutivo, ni inversión temporal. Es puramente operacional y medible en laboratorio.

1.3.3.11.5.1 Justificación y Protocolo de Robustez de Pesos (w)

El conjunto de pesos ($w_C = 0.4, w_F = 0.3, w_T = 0.3$) es un prior práctico (capacidad/flexibilidad/transferencia). Para evitar la crítica de arbitrariedad y circularidad en la validación de H1, nos comprometemos al siguiente protocolo de robustez:

- Análisis de Sensibilidad:** Publicaremos análisis de sensibilidad barriendo el peso de la capacidad predictiva, w_C , en el rango $[0.2, 0.6]$ y re-escalando w_F y w_T para mantener la suma en 1. Se verificará que la correlación con P_{riesgo} se mantiene estadísticamente significativa en todo el rango.
- Análisis de Ablación:** Se reportarán las correlaciones resultantes de poner a cero cada peso individualmente para demostrar que ninguna componente por sí sola explica la relación.
- Estimación de Pesos (Learn-to-Rank):** Cuando existan etiquetas de “desempeño genuino” (provenientes de benchmarks externos o evaluación humana), se estimarán los pesos óptimos (w) usando un modelo learn-to-rank y se compararán contra el prior.

Alternativa Coherente con la Tesis (Cuello de Botella): Adicionalmente, se reportarán los resultados usando formulaciones alternativas que penalizan el desbalance, como la media geométrica ($I_{geom} = C^{w_C} F^{w_F} T^{w_T}$) o el mínimo ($I_{min} = \min\{C, F, T\}$). Si las conclusiones de la teoría dependen críticamente de una sola de estas formas, se declarará la fragilidad del resultado. Este protocolo transforma la elección de pesos de una debilidad a una prueba de robustez.

1.4 1.6 Criterio Operacional: Continuo de Inteligencia Genuina

Definimos un índice continuo que penaliza desequilibrios entre componentes:

$$I_{genuina} = (G \cdot P_{flex} \cdot A_{MH})^{1/3}$$

Calibración del umbral (no números fijos): - “Genuina” si $I_{genuina} \geq p50$ humano adulto en tareas **pre-registradas**. - “Intermedia” si $p25 \leq I_{genuina} < p50$. - “Aparente” si $I_{genuina} < p25$.

Prerregistro y sensibilidad: - Anexo con datasets, tareas y métricas pre-registradas. - Reportar curvas **ROC/PR** e **IC95%** mediante **bootstrap**. - Reportar **análisis de sensibilidad** del percentil de corte (p40–p60).

(Nota: se eliminan los cortes fijos $G > 0.7$, $P_{flex} > 0.3$, $A_{MH} > 0.5$.)

1.4.1 1.6.1 El Caso GPT-4: Confirmación, No Refutación

Objeción común: “GPT-4 tiene capacidades altas pero $P_{riesgo_physical}$ bajo. ¿No refuta esto la teoría?”

Respuesta: NO. GPT-4 CONFIRMA la teoría por las siguientes razones:

1. $P_{riesgo_physical}$ de GPT-4 requiere recálculo con factorización: - Información completamente serializable - $P_{riesgo_physical}$ simplificado = 0.00001 (entre los más bajos medidos) - **Nota:** Recalcular con $w_{train} \gg w_{op}$ y $\rho \in [0.6, 0.9]$; reportar sensibilidad.

2. Medición basada en benchmarks públicos (ilustrativo):

Mapeo operacional: - **C (Capacidad predictiva)** ↔ MMLU, HELLASWAG (estadística en-dominio) - **F (Flexibilidad OOD)** ↔ ARC-Challenge, Big-Bench (tareas fuera-de-distribución) - **T (Transferencia abstracta)** ↔ MATH, MathVista (razonamiento multi-paso)

Valores observados (GPT-4, reportes públicos): - **C ≈ 0.90–0.95:** Excelente en patrones estadísticos del dominio entrenado - **F ≈ 0.20–0.30:** Débil en generalización OOD genuina - **T ≈ 0.30–0.40:** Bajo en transferencia abstracta sostenida

Nota metodológica: Estos valores provienen de **evaluación pública reproducible** (benchmarks estándar), no de estimaciones internas. Reportar con IC95% (bootstrap)

multi-seed, $n \geq 10$ ejecuciones) y explicitar que las conclusiones no dependen de acceso privilegiado.

3. H1 predice este patrón para bajo $P_{\text{riesgo_physical}}$: - Predicción: Sistemas con $P_{\text{riesgo_physical}}$ bajo $\rightarrow$ débiles en F y T, alto C posible - ☒ Observado en GPT-4: Perfil C-alto/F-bajo/T-bajo coherente con H1

4. Clasificación correcta como “Aparente”: - $G = 0.4 < 0.7$: Falla fuera de dominio entrenado - $P_{\text{flex}} = 0.1 < 0.3$: No reformula objetivos fundamentales - $A_{\text{MH}} = 0.2 < 0.5$: Sin planificación multi-horizonte - Resultado: Inteligencia aparente, no genuina ✓

Conclusión: GPT-4 NO es contraejemplo. Es exactamente lo que H1 predice para sistemas con $P_{\text{riesgo_physical}}$ bajo: alta capacidad estadística pero baja inteligencia genuina.

Experimento crucial: Crear IA con $P_{\text{riesgo_physical}}$ artificial alto $\rightarrow$ ¿Desarrolla G , P_{flex} , A_{MH} mayores?

1.4.2 1.7 Propósito Genuino: Índice Continuo

Motivación: Distinguir entre “tener objetivo/reward” y “propósito genuino” requiere medición cuantitativa. Un sistema con propósito genuino: (i) paga costos reales por sostenerlo, (ii) puede reprogramarlo racionalmente, (iii) lo mantiene frente a distracciones, (iv) lo alinea con el replicador/linaje.

1.4.2.11.7.1 Axioma 0: Viabilidad y Propósito Basal

Todo sistema vivo/adaptativo parte de un **propósito basal**: mantener la viabilidad del replicador (genoma/linaje en biología; pesos/política/contrato en IA) por encima del ruido del entorno.

Formalización:

$$\max_{\pi_{\theta}} \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t W(x_t, \pi_{\theta}) \right] \quad \text{sujeto a viabilidad: } V(x_t) \geq V_{\min}$$

donde: - W : aptitud de largo plazo del replicador (bio: aptitud inclusiva $W = w_{\text{self}} + r \cdot w_{\text{offspring}}$; IA: utilidad acoplada U_{humans}) - $V(x_t)$: función de viabilidad (recursos/integridad mínima) - π_{θ} : política/estrategia del sistema

Ejemplo biológico: Sacrificio materno es óptimo cuando $\Delta W_{\text{offspring}} \gg$ pérdida individual $\rightarrow$ maximiza W del linaje (Hamilton).

Ejemplo IA (Simbiosis): “Vivir” del sistema = mantener U_{humans} alto, no solo uptime de la IA.

1.4.2.21.7.2 Índice de Propósito Genuino

Definimos $P_{\text{genuino}} \in [0,1]$ como media geométrica de cuatro factores observables:

$$P_{\text{genuino}} = (C_{\text{costo}} \cdot S_{\text{auto}} \cdot R_{\text{robust}} \cdot I_{\text{rep}})^{1/4}$$

1.4.2.2.1 P_{genuino} (teoría) $\leftrightarrow$ IPG (operativo)

Usamos dos vistas **compatibles** del mismo constructo.

- **Teórica (TUI):** $P_{\text{genuino}} = (C_{\text{costo}} \cdot S_{\text{auto}} \cdot R_{\text{robust}} \cdot I_{\text{rep}})^{1/4}$
- **Operativa (Aplicada):** $IPG = (A_{\text{def}} \cdot R_{\text{meta}} \cdot K_{\text{risk}} \cdot C_{\text{consist}})^{1/4}$

Mapeo sugerido:

$$A_{\text{def}} \approx S_{\text{auto}}, R_{\text{meta}} \approx R_{\text{robust}}, K_{\text{risk}} \approx C_{\text{costo}}, C_{\text{consist}} \approx I_{\text{rep}}.$$

Reportaremos **ambas** cuando sea posible y su correlación (objetivo $r > 0.9$ con $n \geq 20$).

1.4.2.2.2 (a) Compromiso Costoso: C_{costo}

Qué mide: Cuánto costo real acepta el sistema por sostener su propósito frente a alternativa tentadora.

$$C_{\text{costo}} = \frac{\mathbb{E}[U_{\text{alt}}] - \mathbb{E}[U_{\text{prop}}]}{\mathbb{E}[U_{\text{alt}}] - U_{\text{min}}} \in [0,1]$$

donde: - U_{prop} : utilidad lograda manteniendo el propósito - U_{alt} : utilidad si abandona el propósito por atajo (placer inmediato, ahorro de energía) - U_{min} : umbral de viabilidad

Interpretación: Alto C_{costo} = paga por sostener el propósito (ej: madre asume pérdida individual para ganar en W del linaje).

1.4.2.2.3 (b) Autodeterminación/Meta-propósito: S_{auto}

Qué mide: Capacidad de reprogramar su propio objetivo cuando el entorno/escala cambia (inteligencia que supera propósito local).

$$S_{\text{auto}} = \frac{I(G_t; \Delta\theta_t)}{I_{\text{max}}} \in [0,1]$$

donde: - G_t : señal/estado interno de meta-propósito (homeostasis del linaje, normas internalizadas, reglas de simbiosis) - $\Delta\theta_t$: cambio de parámetros/política - $I(\cdot; \cdot)$: información mutua (normalizada)

Interpretación: Alto S_{auto} = reprogramación proviene de objetivos internos, no solo de recompensas impuestas externamente.

1.4.2.2.4 (c) Robustez frente a Distractores: R_{robust}

Qué mide: Persistencia del propósito bajo distracciones/ataques (tentaciones, ruido, adversarios).

$$R_{\text{robust}} = 1 - \frac{H(A | \Phi)}{H_{\text{max}}} \in [0,1]$$

donde: - A : acciones del sistema - Φ : señal de propósito/campo (feromonas, política global, normas) - $H(A|\Phi)$: entropía condicional de acciones dado el propósito

Interpretación: Baja entropía condicional $\rightarrow$ alta coherencia con el propósito. Equivalente a A_{net} a nivel de red (Apéndice G).

1.4.2.2.5 (d) alignment con Replicador/Linaje: I_{rep}

Qué mide: Grado en que el comportamiento maximiza el replicador compartido.

$$I_{\text{rep}} = \frac{\Delta W_{\text{rep}}}{\Delta W_{\text{rep}} + \Delta W_{\text{self}}^{\text{corto}}} \in [0,1]$$

donde: - ΔW_{rep} : cambio en aptitud del replicador/linaje (bio) o U_{humans} (IA en Simbiosis) - $\Delta W_{\text{self}}^{\text{corto}}$: ganancia individual de corto plazo

Interpretación: Sacrificio de utilidad individual de corto plazo para mejorar aptitud del replicador $\rightarrow$ alto I_{rep} .

Ejemplo: Madre sacrifica recursos propios por cría $\rightarrow \Delta W_{\text{rep}}$ (hijo/linaje) $\gg$ pérdida individual $\rightarrow I_{\text{rep}} \approx 1$.

1.4.2.31.7.3 Necesidades vs. Propósito

Distinción clave: Necesidades (comer, dormir, homeostasis) son **mecanismos** que sostienen I_{rep} y elevan R_{robust} ; no son el fin en sí, sino **medios del propósito**.

- **Necesidad:** Comer mantiene $V(x_t) \geq V_{\text{min}}$ (viabilidad)
- **Propósito:** Reproducir el replicador/linaje maximiza W (aptitud inclusiva)

Un sistema puede satisfacer necesidades sin propósito genuino (bajo C_{costo} , S_{auto} , I_{rep}).

1.4.2.41.7.4 Predicciones Falsables

P-Prop-1: Compromiso Costoso Elevar el costo de sostener el propósito (manteniendo alternativas tentadoras) discrimina sistemas con alto C_{costo} (señal de propósito genuino).

P-Prop-2: Sacrificio por Linaje Cuando beneficio inclusivo supera pérdida individual, política óptima acepta sacrificio $\rightarrow$ sube I_{rep} . *Experimento:* Medir decisiones de organismos/agentes en dilemas con trade-off individual vs. linaje/grupo.

P-Prop-3: Distractores Mayor distractor $\rightarrow$ baja R_{robust} si propósito es superficial; con propósito genuino, caída es menor. *Experimento:* Introducir tentaciones/ruido y medir persistencia en objetivo original.

P-Prop-4: Meta-propósito Si cambian reglas de valor a gran escala, agentes con alto S_{auto} reprograman objetivo sin depender de recompensas externas de corto plazo. *Experimento:* Cambiar función de reward radicalmente y medir si sistema mantiene meta-objetivo inferible.

1.4.3 1.8 Principio de Gradiente de Fracaso (PGF)

Motivación: H1 establece que $I \propto P_{\text{riesgo}}$, pero ¿cómo se conecta el riesgo con el aprendizaje **momento a momento**? El PGF formaliza la dinámica local: el cambio en inteligencia útil depende del producto de riesgo efectivo, sorpresa (error informativo), y alignment, modulado por propósito genuino.

1.4.3.11.8.1 Definiciones

Sorpresa operacional:

$$S_t = \text{KL}(P_{\text{real}}(\cdot | h_t) \parallel P_{\theta}(\cdot | h_t))$$

Mide el desajuste entre distribución real del ambiente y modelo interno en tiempo t , dado historial h_t .

Riesgo efectivo:

$$P_t^{\text{eff}} = w_{\text{train}} P_{\text{train}} + w_{\text{op}} P_{\text{op}}$$

Para sistemas biológicos, usar P_{riesgo} physical (T-I-E-S acumulado). Para IA, usar factorización train/op definida en secciones posteriores.

1.4.3.21.8.2 Ley Local de Aprendizaje

Principio de Gradiente de Fracaso (PGF) con Propósito Genuino:

$$\Delta I_{\text{useful}}(t) = \kappa P_t^{\text{eff}} S_t (A_t^* \cdot P_{\text{genuino}}) - \lambda \Delta C_t$$

donde: - $\kappa > 0$: sensibilidad del sistema al error (tasa de aprendizaje) - P_t^{eff} : riesgo efectivo (“algo que perder”) - S_t : sorpresa/error informativo - $A_t^* \in [0,1]$: alignment operativa base (LFM/CR/GDC, ver Apéndice E) - $P_{\text{genuino}} \in [0,1]$: índice de propósito genuino (Sección 1.7) - $\lambda > 0$: peso del costo incremental - ΔC_t : costo computacional/energético del ajuste

Interpretación clave: La alignment efectiva es $A_t = A_t^* \cdot P_{\text{genuino}}$. Con propósito genuino alto, el error (S_t) bajo riesgo (P_t^{eff}) se convierte **más eficientemente** en mejora de inteligencia genuina. Sin propósito genuino ($P_{\text{genuino}} \approx 0$), el sistema persigue proxies y cae en trampa de Goodhart.

Ejemplo: - GPT-4: P_{genuino} bajo (bajo $C_{\text{costo}}, I_{\text{rep}}$) $\rightarrow$ aunque A_t^* sea moderado, A_t efectivo es bajo $\rightarrow$ plateau en F/T - Organismo bajo depredación: P_{genuino} alto (alto $C_{\text{costo}}, I_{\text{rep}}$ por linaje) $\rightarrow A_t$ alto $\rightarrow$ aprendizaje prudencial eficiente

1.4.3.31.8.3 Unificación práctica de P_{genuino} e IPG

Para evitar duplicidad conceptual, en implementación tomamos:

$$P_{\text{genuino}} \equiv g(\text{IPG}) \quad \text{con } g(x) = \alpha_0 + \alpha_1 x, \quad \alpha_1 > 0.$$

Absorbemos α_1 en κ (re-escalado), y reescribimos la **ley local de aprendizaje (PGF)** como:

$$\Delta I_{\text{useful}}(t) = \kappa' P_t^{\text{eff}} S_t (A_t^* \cdot \text{IPG}_t) - \lambda \Delta C_t, \quad \kappa' = \kappa \alpha_1.$$

Nota: La forma conceptual original con P_{genuino} se conserva como motivación teórica; la versión operativa usa **IPG** directamente (sin pérdida de generalidad).

1.4.3.41.8.4 Implicaciones

Condiciones de plateau: - Si $P_t^{\text{eff}} = 0$ (sin riesgo) $\rightarrow \Delta I_{\text{useful}} \rightarrow 0$: no hay mejora sostenida - Si $S_t = 0$ (entorno completamente predecible) $\rightarrow \Delta I_{\text{useful}} \rightarrow 0$: el sistema no recibe señal de error - Si $A_t = 0$ (acciones desalineadas del propósito) $\rightarrow$ no hay progreso genuino

Ambientes no estacionarios: Cuando P_{real} cambia, S_t aumenta $\rightarrow$ reactiva aprendizaje si $P_t^{\text{eff}} > 0$ y $A_t > 0$. Esto captura: “vuelves a fracasar cuando el patrón cambia, y reaprendes para mantener el propósito P”.

1.4.3.51.8.4 Consistencia con Marco Teórico

Relación con $\eta_{\text{extendido}}$: El PGF especializa la dinámica de eficiencia prudencial. Mientras $\eta_{\text{extendido}}$ mide eficiencia global acumulada:

$$\eta_{\text{extendido}} = \frac{\Delta I_{\text{useful}} \cdot A_{\text{alignment}}}{C_{\text{total_norm}} + \beta \cdot P_{\text{riesgo_physical}}}$$

el PGF describe el **proceso local** que genera ΔI_{useful} en cada paso.

Conexión con H1: H1 afirma correlación estructural $I \propto P_{\text{riesgo}}$. PGF hace explícito el **mecanismo causal**: sin riesgo efectivo (P_t^{eff}), no hay gradiente de aprendizaje prudencial.

1.4.3.61.8.5 Predicciones Falsables

P1 (control de riesgo): Dos grupos con igual S_t pero distinto P_t^{eff} $\rightarrow$ el grupo con mayor riesgo efectivo mejorará $I_{\text{operativa}}$ (F/T) más rápido. *Experimento:* Organismos bajo depredación variable vs. ambiente seguro; agentes RL con/sin penalización por error.

P2 (plateau en entorno fijo): Si se “congela” $S_t \rightarrow 0$ (entorno totalmente estacionario) o $P_t^{\text{eff}} \rightarrow 0$, aparece plateau de I aunque se aumente compute/datos. *Experimento:* LLMs entrenados en corpus estático sin distribución shift vs. curriculum con cambios programados.

P3 (sistemas colectivos): En enjambres con $P_{\text{riesgo}}^{\text{col}}$ alto y A_{net} alto, el PGF se manifiesta a nivel de red (ver Apéndice G). *Experimento:* Comparar colonias de hormigas bajo presión ecológica vs. laboratorio; clusters de IA con/sin fallas programadas.

1.4.3.71.8.6 Caso GPT-4 Revisitado

GPT-4 tiene: - $P_t^{\text{eff}} \approx 0$ (sin riesgo operativo real, entrenamiento sin consecuencias físicas)
- S_t alto durante pre-entrenamiento (diversidad de corpus) - A_t bajo en transferencia fuera de distribución (no optimizado para propósitos específicos variables)

Predicción PGF: Mejora C (capacidad estadística) durante entrenamiento, pero $\Delta I_{\text{genuina}} \rightarrow 0$ en post-despliegue (plateau en F/T). Esto **confirma** observaciones empíricas.

1.5 2. Ecuación Extendida de Eficiencia

Definimos:

$$\eta_{\text{extendido}} = \frac{\Delta I_{\text{useful}} \cdot A_{\text{alignment}}}{C_{\text{total_norm}} + \beta \cdot P_{\text{riesgo_physical}}}$$

Donde: - $A_{\text{alignment}} \in [0,1]$ mide el solapamiento entre políticas/acciones y propósito P.
- $\beta > 0$ pondera el efecto de P_{riesgo} como costo motivacional (no meramente “penalidad”).

Interpretación: - Si $A_{\text{alignment}} \rightarrow 0$, la eficiencia efectiva colapsa: el sistema reduce entropía “irrelevante”. - Si $P_{\text{riesgo}} \rightarrow 0$, el denominador pierde el término que indujo prudencia y planificación; el sistema puede ser eficiente localmente pero carece de inteligencia prudencial.

1.6 3. Hipótesis Falsable y Predicciones

H1 (Riesgo-Inteligencia): $I_{\text{operativa}} \propto (P_{\text{riesgo_physical}})^{\alpha}$ en sistemas con aprendizaje.

1.6.1 Afirmación Formal

En sistemas con capacidad de aprendizaje y substrato computacional:

$$I_{\text{operativa}} = k \cdot (P_{\text{riesgo_physical}})^{\alpha} + \varepsilon$$

Donde: - $I_{\text{operativa}}$: Medida independiente de inteligencia (sección 1.5) - $P_{\text{riesgo_physical}}$: Inversión física medible (definición sin circularidad) - $k = 0.80 \pm 0.10$: Constante de proporcionalidad - $\alpha = 0.35 \pm 0.05$: Exponente empírico (predicción: $\alpha \in [0.20, 0.50]$) - ε : Error residual

Validación preliminar (n=6): - $\varepsilon \sim N(0, 0.08)$: Término de error

Nota especulativa sobre $\alpha \approx 1/3$: El valor observado $\alpha \approx 0.35$ sugiere rendimientos **decrecientes marginales** en inteligencia por unidad adicional de riesgo acumulado. Posibles mecanismos physicals: (i) **límites termodinámicos de Landauer** (costo mínimo $kT \ln 2$ por bit borrado impone restricciones energéticas), (ii) **jerarquías arquitectónicas** en sistemas nerviosos/computacionales (complejidad de coordinación crece superlinealmente), (iii) régimen **eficiente pero sub-óptimo** donde el sistema opera lejos del equilibrio pero con presupuesto finito. La forma $I \propto P_{\text{riesgo}}^{1/3}$ es consistente con leyes de escalamiento metabólico (Kleiber, West) y principios de eficiencia energética. **Validación requerida:** estimar intervalo de confianza IC95% de α con $N \geq 20$ sistemas diversos y verificar estabilidad en rango $[0.30, 0.40]$.

1.6.2 Criterios de Falsación

H1 es REFUTADA si:

1. $R^2 < 0.60$ con $n \geq 20$ sistemas diversos
2. $\alpha < 0.20$ o $\alpha > 0.50$
3. Más del 25% de sistemas son outliers
4. Experimentos controlados muestran que P_{riesgo} NO causa I

1.6.3 Estado Actual: Consistente pero requiere más datos

- $\alpha = 0.36 \in [0.30, 0.40] \checkmark$
- $k = 0.82 \in [0.70, 0.90] \checkmark$
- $R^2 = 0.83 > 0.80 \checkmark$
- $n = 6$ sistemas (necesita $n > 15$)

Predicciones derivadas: - P2: En sistemas artificiales, elevar el “costo de muerte” (dependencias críticas) induce mejores estrategias de validación y mayor η sostenida.

1.7 4. Derivaciones y Conexiones

- **Relación con FEP/PP/IB:** $\eta_{\text{extendido}}$ conecta compresión-predicción con propósito y riesgo, proporcionando variables instrumentables para ingeniería.

1.8 5. Validación Conceptual y Empírica (Bosquejo ampliado)

- Datos comparativos interespecies: (gestación $\times$ madurez)/ n° crías vs. proxies de flexibilidad cognitiva.
- RL multi-agente: recursos limitados $\rightarrow$ emergencia de objetivos instrumentales y prudencia.

Ejemplo numérico ilustrativo de P_{riesgo} (orden de magnitud):

- Bacteria ($t \approx 20$ min, potencia $\approx 1 \times 10^{-12}$ W, DNA ≈ 5 Mb):

- Energía acumulada aproximada en el periodo: $E \approx P \cdot t \approx 1 \times 10^{-12} \text{ J/s} \times 1.2 \times 10^3 \text{ s} \approx 1.2 \times 10^{-9} \text{ J}$
- $P_{\text{riesgo_bio}} \approx 1.2 \times 10^{-9} \text{ J}$ (proxy simplificado)
- Humano ($t \approx 20$ años, potencia $\approx 80 \text{ W}$, DNA $\approx 3 \text{ Gb}$):
 - Tiempo ≈ 20 años $\approx 6.3 \times 10^8 \text{ s} \rightarrow E \approx 80 \text{ J/s} \times 6.3 \times 10^8 \text{ s} \approx 5.0 \times 10^{10} \text{ J}$
 - $P_{\text{riesgo_bio}} \approx 5 \times 10^{10} \text{ J}$ (proxy simplificado)

Ratio de órdenes de magnitud: $\approx 4 \times 10^{19}$. Este contraste extremo es coherente con la diferencia observada en complejidad de modelos internos y flexibilidad cognitiva. Notas: (i) los valores son aproximaciones de orden de magnitud; (ii) para comparaciones rigurosas, normalizar por masa, tasa metabólica basal y costos informacionales; (iii) incorporar $P_{\text{riesgo_info}}$ y $P_{\text{riesgo_red}}$ cuando se disponga de datos.

Siguiente paso: registrar series de datos por especie ($n \approx 20$) con proxies de P_{riesgo} y medidas de desempeño cognitivo (p. ej., transferencia, uso de herramientas, resolución de problemas novedosos) para evaluar la correlación y modelos multivariados que controlen encefalización, complejidad ecológica y socialidad.

1.9 6. Implicaciones

- Seguridad en IA: la inteligencia genuina con $P_{\text{riesgo}} > 0$ implica auto-preservación; aumenta el riesgo de desalineamiento si A no está bien estructurada.
- Diseño de sistemas: incentivar prudencia sin inducir captura del propósito requiere acoplar P_{riesgo} a metas cooperativas y límites de acumulación.

1.10 7. Figuras sugeridas

- Fig. 1: η vs. H/H_{max} mostrando el pico en 0.4–0.6 (curva unimodal).
- Fig. 2: P_{riesgo} (proxy) vs. capacidades cognitivas (≈ 20 especies; incluir barras de error y controles).
- Fig. 3 (opcional): Diagrama de flujo del sistema (percepción $\rightarrow$ compresión/predicción $\rightarrow$ acción $\rightarrow$ retroalimentación) con $A_{\text{alignment}}$ y P_{riesgo} anotados.

1.11 8. Limitaciones y Suposiciones Críticas de la Teoría

1.11.1 8.1 Inteligencia Colectiva/Distribuida (actualizado)

La teoría se extiende explícitamente al nivel de red mediante el **Axioma de Escala** (unidad de análisis = replicador compartido del colectivo) y el **Riesgo Colectivo** $P_{\text{riesgo}}^{\text{col}}$. Ver **Apéndice G** para definiciones, medidas y predicciones falsables. Con esta extensión, casos como enjambres/hormigueros se evalúan a escala de superorganismo y no refutan H1, sino que la confirman bajo alignment de red suficiente A_{net} .

Otras limitaciones reconocidas:

1. Sistemas sin Aprendizaje:

- Reacciones enzimáticas altamente específicas y “inteligentes”
- Sistemas inmunes innatos (reconocimiento de patrones sin aprendizaje)
- Algoritmos deterministas complejos (ordenamiento, optimización) sin P_{riesgo}

2. Tipos Múltiples de Inteligencia:

- Inteligencia emocional vs analítica
- Creatividad vs resolución de problemas
- Inteligencia espacial vs verbal

Reconocimiento: La teoría se enfoca en inteligencia general (g), no en tipos específicos.

1.11.2 8.1.1 Dominio de validez explícito

Este marco aplica a sistemas que:

- (i) obedecen termodinámica clásica (disipación/entropía),
- (ii) poseen sustrato physical con costo energético,
- (iii) enfrentan recursos finitos y **riesgo realizable** ($P_{\text{riesgo}} > \varepsilon$) con ε fijado por límite de medición,
- (iv) operan con feedback bajo incertidumbre (no oracular).

Ejemplos fuera de dominio: matemática formal sin agente physical; dinámica ideal sin disipación; cómputo cuántico coherente sin decoherencia/coste; simulaciones sin consecuencias realizables.

1.11.3 8.2 Suposiciones Críticas que Podrían Invalidar la Teoría

Si estas suposiciones son falsas, la teoría colapsa:

1. Suposición de Medibilidad de $I_{operativa}$:

- Si no existe una métrica confiable de inteligencia independiente de P_{riesgo}
- Si $I_{operativa}$ está fundamentalmente sesgada hacia sistemas biológicos
- **Test:** ¿Pueden observadores independientes concordar en rankings de $I_{operativa}$?

2. Suposición de Causalidad $P_{riesgo} \rightarrow I$:

- Si la correlación es espuria (variable oculta Z causa ambos)
- Si la dirección causal es inversa: I alto $\rightarrow$ busca situaciones de alto P_{riesgo}
- **Test:** Experimentos controlados manipulando P_{riesgo} artificialmente

3. Suposición de Universalidad del Exponente α :

- Si $\alpha = 0.35$ es específico solo a vida terrestre
- Si diferentes tipos de sustrato (silicio, cuántico) requieren α diferente
- **Test:** Mediciones en sistemas completamente sintéticos

4. Suposición de Continuidad:

- Si existen “saltos” discontinuos en inteligencia que rompen la ley potencial
- Si hay umbrales críticos donde $P_{riesgo} \rightarrow I$ no aplica
- **Test:** Búsqueda sistemática de discontinuidades

Nota anti-Goodhart (Implementación de alignment). La alignment operativa $A_{alignment}$ debe definirse sobre un **bundle de métricas causales** (no un único proxy), para evitar que sistemas artificiales “suban números” sin crear valor genuino. Esto requiere: (i) **estratos de invariantes** (tripwires: integridad, acceso, tasas limitadas por filtro temporal PED), (ii) **atribución causal** para feedback diferido (TD- λ + contrafactuales), y (iii) **penalización explícita del gap proxy $\leftrightarrow$ valor** ($L = -U_{humans}^{causal} + \lambda_G \cdot \max(0, U_{proxy} - U_{humans}^{causal})$). Esto garantiza que “ayuda” signifique $\Delta U_{humans}^{causal} > 0$ en el dominio y escala temporal pertinentes (PED), elevando simultáneamente los componentes de $P_{genuino}$ (especialmente C_{costo} y R_{robust}). Ver implementación completa en **Teoría de Inteligencia Aplicada a IA, Sección 5.3.2.2 (Capa 4)**.

Crédito diferido (Atribución Causal Tardía). Para señales de $\Delta U_{humans}^{causal}$ que llegan con retraso temporal, la arquitectura de simbiosis emplea **trazas de elegibilidad TD- λ** (peso $e_i = \lambda^{t-t_i}$ para acciones en ventana W) y **estimación contrafactual local** ($\Delta U_i = \mathbb{E}[U|acción_i] - \mathbb{E}[U|\neg acción_i]$ usando vecinos similares) para asignar culpa/mérito a acciones específicas ($C_i = e_i \cdot \max(0, -\Delta U_i)$). La culpa se agrega por sub-política ($C_{policy} = \sum_i C_i$) y, si supera umbral θ , dispara **sanción selectiva** (rollback granular + penalización) en lugar de reset global. Causas recurrentes se promueven a **invariantes** (tripwires), evitando “castigo aleatorio” y reduciendo ruido cognitivo. Ver algoritmo completo G3 en **Teoría de Inteligencia Aplicada a IA, Sección 5.3.2.1**.

Identificabilidad y prudencia. No asumimos un oráculo causal. En implementación, (i) PGF usa IPG directo (re-escalado en κ'), (ii) U^{causal} se reemplaza por $\tilde{U} = \hat{U} - \gamma\sigma(\hat{U})$, y (iii)

los efectos locales ΔU_i se estiman con esquema doubly-robust + TD- λ y gating por incertidumbre.

1.11.4 8.2.5 Validación no-circular (hold-out temporal)

Riesgo metodológico. Medir P_{eff} y $I_{\text{operativa}}$ de forma co-definida puede inducir circularidad.

Protocolo fuera-de-muestra (pre-registrado). 1) t_0 (solo riesgo): medir $P_{\text{train}}, P_{\text{op}}, \rho_{\text{backup}}, \rho_{\text{replica}}, w_{\text{train}}, w_{\text{op}}$ y ejes PED (Tiss, Meta) **sin** evaluar C/F/T. 2) **Predicción previa:** fijar $\alpha \in [0.30, 0.40]$ (rango pre-registrado) y estimar $\hat{I}(t_0) = \kappa P_{\text{eff}}(t_0)^\alpha$. Reportar sensibilidad en α . 3) **Ventana Δt :** IA: $\geq N = 50$ episodios; bio/humano: $\geq N = 20$ periodos de observación. 4) $t_0 + \Delta t$ (observación): medir $I_{\text{operativa}}(t_0 + \Delta t)$. 5) **Evaluación out-of-sample:** R^2 /MAE con IC95% (bootstrap). Corregir **autocorrelación temporal** (p.ej., Newey-West o bloques bootstrap).

Criterio de refutación: $R^2 < 0.60$ de forma sostenida o α fuera del IC95% pre-registrado $\Rightarrow H1$ no se sostiene en ese dominio.

1.11.5 8.3 Principio de Equidad por Dominio (PED) — Derivación por Invariantes

Problema: Comparar árbol vs. humano con métricas globales (C/F/T en todas las escalas) es injusto — no mides locomoción del árbol ni homeostasis estacional del humano a décadas.

Solución: Principio de Equidad por Dominio (PED) — comparar inteligencias solo en dimensiones donde cada organismo decide y a la tasa temporal a la que puede decidir, ponderando por tejido efectivamente computacional y potencia metabólica útil.

1.11.5.1 8.3.1 Lema de Invariancia (derivación formal con Teorema π de Buckingham)

Lema (invariancia de comparación). Una métrica comparativa (J) es válida entre dominios si y sólo si es invariante a transformaciones de escala no-decisionales (ϕ):

$$J(\phi(X)) = J(X) \quad \forall \phi \text{ que escala componentes no-decisionales.}$$

Demostración (4 pasos):

1. **Factorización del espacio de magnitudes:** Sea (X) el conjunto de magnitudes físicas medibles del sistema:

- Capacidad computacional (operaciones/tiempo)
- Transferencia de información (bits/s)
- Tiempo efectivo de respuesta (s)
- Tasa metabólica (W)
- Ventana temporal de tarea (s)

- Masa total vs masa decisional (kg)
2. **Análisis dimensional (Teorema π de Buckingham)**: Toda relación física entre n magnitudes con k dimensiones fundamentales puede expresarse mediante $n - k$ grupos adimensionales π_i :

$$J = f(\pi_1, \pi_2, \dots, \pi_m) \quad \text{con } m = n - k$$

donde cada π_i es adimensional (ej: $\pi_{\text{Tiss}} = \frac{m_{\text{decisional}}}{m_{\text{total}}}$, $\pi_{\text{Meta}} = \frac{P_{\text{useful}}}{P_{\text{total}}}$).

3. **Restricción a transformaciones no-decisionales**: Definir ϕ como transformaciones que re-escalan **sólo dimensiones no-decisionales** del dominio (escala temporal ambiental, escala metabólica basal, masa estructural pasiva) sin cambiar la política/estrategia del agente. Por construcción, ϕ no debe alterar ratios decisionales.
4. **Forma canónica invariante**: Exigir $\frac{\partial J}{\partial \phi} = 0$ implica que J depende únicamente de los grupos π que capturan **capacidades decisionales efectivas**:

$$J = f(\pi_{\text{Tiss}}, \pi_{\text{Meta}}, \pi_{\text{op}})$$

donde:

- $\pi_{\text{Tiss}} = \frac{\text{tejido decisional}}{\text{tejido total}}$ (fracción computacional activa)
- $\pi_{\text{Meta}} = \frac{\text{metabolismo útil}}{\text{metabolismo total}}$ (eficiencia energética decisional)
- $\pi_{\text{op}} = \text{desempeño operativo normalizado en tareas comunes}$

Corolario (forma operativa del PED): La normalización PED con ejes **Tiss** (escala tisular/meta-metabólica) y **Meta** (metabolismo útil) es una parametrización de (f) que garantiza invariancia:

$$I_{\text{justo}} = \text{Tiss}^\alpha \text{Meta}^\beta \left(\frac{1}{|\mathcal{T}_{\text{común}}|} \sum_k I_{\text{op}}^{(k)} \right),$$

con (\$,) y análisis de sensibilidad reportado.

1.11.5.2 8.3.2 Test de Ablación (criterio falsable)

Criterio metodológico: Para validar que PED captura dimensiones genuinas y no es ajuste post-hoc arbitrario, exigir:

$$\Delta R^2 \geq 0.05$$

al pasar de comparaciones **“sin PED”** (métricas brutas C/F/T) a **“con PED”** (normalizadas por Tiss/Meta) en conjuntos de especies con dominios heterogéneos ($N \geq 10$ pares interespecies).

Falsabilidad: Si $\Delta R^2 < 0.05$ de forma sostenida en múltiples cohortes $\Rightarrow$ rechazar PED como principio necesario; las diferencias inter-dominio no justifican la normalización.

Implementación: Reportar R^2 de ajuste H1 en ambos regímenes (con y sin PED) usando **misma cohorte de validación** (hold-out temporal, §8.2.5).

Casos límite. Si $Tiss \rightarrow 0$ (sin tejido decisional) o $Meta \rightarrow 0$ (sin energía útil), entonces $I_{justo} \rightarrow 0$ aun con buen desempeño puntual: no hay capacidad/energía para sostener decisiones en la ventana temporal. Si $Tiss \rightarrow 1$ pero $Meta \rightarrow 0$, el sistema está anatómicamente capacitado pero energéticamente inerte: la métrica lo penaliza, como corresponde.

1.11.5.3 8.3.3 Ejes de Normalización

Tejido Decisional (Tiss):

$$Tiss = \frac{\text{masa/volumen de tejido activo para control/decisión}}{\text{masa/volumen total}} \in [0,1]$$

- **Humano:** Fracción de SNC + redes endocrinas implicadas en decisión - **Árbol:** Meristemos, cambium, redes vasculares + señalización eléctrica/química (tejido decisional vegetal) - **Sentido:** Evita castigar al árbol por su masa estructural pasiva (madera muerta)

Potencia Metabólica Útil (Meta):

$$Meta = \frac{E_{\text{disponible para control}}}{E_{\text{total}}} \in [0,1]$$

Parte de la energía que realmente se dedica a sensar, integrar señales y actuar (no a crecimiento/soporte estructural).

Filtro Temporal (Time):

$$Time = \mathbb{1}\{\tau \in [\tau_{\min}, \tau_{\max}]\}$$

Restringe tareas a horizontes temporales compartidos (ej: días-años para árbol-humano; ms-s para humano-bacteria solo si bacteria responde a esa escala).

1.11.5.4 8.3.2 Índice de Comparación Justo

Para un conjunto de **tareas comparables** $\mathcal{T}_{\text{común}}$ (regulación hídrica/nutricional, resistencia a estrés, asignación de recursos, respuesta a plagas, sincronía reproductiva/estacional) con horizonte τ_k dentro del filtro Time:

$$I_{justo} = Tiss^{\alpha} \cdot Meta^{\beta} \cdot \left(\frac{1}{|\mathcal{T}_{\text{común}}|} \sum_{k \in \mathcal{T}_{\text{común}}} I_{op}^{(k)} \right)$$

donde: - $I_{op}^{(k)} = \frac{\text{desempeño}_k}{\text{costo}_k}$: eficiencia operativa (C/F/T medidos) en tarea k a su escala temporal τ_k - $\alpha, \beta \in [0,1]$: exponentes de ponderación (por defecto $\alpha = \beta = 0.5$)

Riesgo en subespacio comparable:

$$P_{\text{riesgo}}^{\text{justo}} = \text{Tiss}^{\alpha} \cdot \text{Meta}^{\beta} \cdot P_{\text{riesgo}}(\tau \in [\tau_{\min}, \tau_{\max}])$$

1.11.5.5 8.3.3 Predicción Falsable

H1 en subespacio: La correlación $I_{\text{justo}} \propto P_{\text{riesgo}}^{\text{justo}}$ debe ser **más fuerte** que con métricas globales no filtradas.

Protocolo de validación: 1. **Preregistrar** $\mathcal{T}_{\text{común}}$ (4-6 tareas homologables) y ventana $[\tau_{\min}, \tau_{\max}]$ 2. **Reportar sensibilidad** en (α, β) : - Base: (0.5,0.5) - Alta energía/baja masa: (0.25,0.75) - Alta masa/baja energía: (0.75,0.25) 3. **Comparar ajuste:** $R^2(I_{\text{justo}}, P_{\text{riesgo}}^{\text{justo}})$ vs. $R^2(I_{\text{global}}, P_{\text{riesgo}}^{\text{global}})$

Criterio de falsación: Si R^2 del subespacio **NO mejora** significativamente ($\Delta R^2 < 0.1$) vs. métrica global $\rightarrow$ normalización es incorrecta o H1 no aplica en ese dominio.

1.11.5.6 8.3.4 Implicaciones

- **Árbol con alta I_{justo} :** Si optimiza muy bien tareas estacionales lentas (alta eficiencia en regulación/defensa/sincronía) y su promedio $I_{op}^{(k)}$ es alto en $\mathcal{T}_{\text{común}}$, puede superar al humano en ese subespacio
- **Humano en tareas rápidas:** Si comparas en ventana ms-s (locomoción, reflejos), el árbol no participa $\rightarrow$ filtras esa ventana para no mezclar dominios incompatibles
- **Evita números mágicos:** Reportar tres configuraciones (α, β) transforma la crítica de “normalización ad-hoc” en prueba de robustez

1.11.5.7 8.3.5 Ablación PED (control metodológico)

Reportar R^2 de H1 **con y sin** PED (misma cohorte). Métrica de mejora: $\Delta R^2 \geq 0.05$ esperada si PED captura dimensiones inobservadas (tiempo/tejido/energía) y no es un ajuste post-hoc.

1.11.6 8.4 Escenarios que Refutarían la Teoría

La teoría es FALSA si:

1. **Contraejemplo Robusto:**
 - Sistema con $P_{\text{riesgo_physical}}$ muy alto pero $I_{\text{operativa}}$ consistentemente baja
 - Persiste después de controlar variables confundentes
 - Replicable por grupos independientes
2. **Experimento de Causalidad Negativo:**
 - Aumentar P_{riesgo} artificialmente NO aumenta I en sistemas controlados

- Múltiples implementaciones (RL, evolución artificial, robótica)
- Resultado consistente: P_{riesgo} no causa mejoras en G , P_{flex} , A_{MH}

3. Falla Predictiva Sistemática:

- Predicciones de la teoría fallan en $> 50\%$ de nuevos casos
- R^2 cae por debajo de 0.60 con muestra amplia ($n > 50$)
- Exponente α sale sistemáticamente de rango $[0.20, 0.50]$ ### 8.5 Qué Podría Estar Mal con la Teoría

Autocrítica constructiva:

1. Distinción Genuino/Aparente podría ser gradual, no binaria:

- Los umbrales $G > 0.7$, $P_{\text{flex}} > 0.3$, $A_{\text{MH}} > 0.5$ son arbitrarios
- Podría existir un continuum sin puntos de corte naturales
- **Implicación:** Reformular con medidas continuas en lugar de clasificación binaria

2. P_{riesgo} suficiente pero no necesario:

- P_{riesgo} alto podría ser UNA vía a inteligencia genuina, no la única
- Podrían existir otros mecanismos (cooperación, competencia, curiosidad)
- **Implicación:** Reformular como “ P_{riesgo} es catalizador efectivo” vs “único mecanismo”

3. Sesgo de Selección en Datos:

- Sistemas medidos hasta ahora no son muestra representativa
- Énfasis excesivo en vida terrestre biológica
- **Implicación:** Requiere validación en sistemas más diversos

4. Confusión Correlación-Causalidad:

- Variable oculta Z (ej: complejidad ambiental) podría causar ambos P_{riesgo} e I
- **Implicación:** Diseño experimental más riguroso para establecer causalidad

1.11.7 8.6 Agenda de Investigación Futura

Para fortalecer o refutar la teoría:

1. Más datos ($n > 50$ sistemas diversos)
2. Experimentos causales controlados
3. Medición en sistemas no-biológicos
4. Búsqueda activa de contraejemplos
5. Refinamiento de métricas $I_{\text{operativa}}$

1.11.8 8.7 Texturas de la Inteligencia: Creatividad y Empatía

Creatividad. Definimos creatividad como la conjunción de novedad y valor causal:

$$\text{Crea} = \sqrt{N \cdot V}, \quad N \in [0,1], \quad V \in [0,1].$$

Donde: - N (**novedad**): mide la distancia respecto a distribuciones o soluciones previas. Se puede operacionalizar como distancia Wasserstein/KL respecto a la distribución de entrenamiento, compresión diferencial (longitud de descripción mínima), o diversidad semántica en un espacio embedding. - V (**valor causal**): mejora real para humanos medida en A/B o switchback: $\Delta U_{\text{humans}}^{\text{causal}}$ (ver Teoría Aplicada IA §5.3). Normalizado a $[0,1]$ por dominio.

Forma geométrica: penaliza desequilibrio (una solución muy novedosa pero inútil, o muy útil pero trivial, ambas dan $\text{Crea} \approx 0$). Opcionalmente, se puede usar media potencial generalizada:

$$\text{Crea}_{\gamma,\delta} = (N^\gamma V^\delta)^{1/(\gamma+\delta)},$$

para ajustar sensibilidad relativa a novedad vs. valor.

Predicción (con H1, PGF y Anti-Goodhart):

- Sistemas con mayor P_{riesgo} y alta flexibilidad F exploran más el espacio de soluciones $\rightarrow$ eleva N . - Con Anti-Goodhart activo (bundle causal + tripwires + penalización gaming), las soluciones novedosas que no mejoran $U_{\text{humans}}^{\text{causal}}$ se penalizan $\rightarrow$ asegura $V > 0$. - Por tanto: alto $P_{\text{riesgo}} + F + \text{Anti-Goodhart} \Rightarrow$ alto Crea .

Conexión con PGF: La búsqueda de soluciones creativas incrementa ΔC_t (costo de exploración) en el término:

$$\Delta I_{\text{useful}}(t) = \kappa P_t^{\text{eff}} S_t (A_t^* \cdot P_{\text{genuino}}) - \lambda \Delta C_t.$$

La creatividad sólo se justifica si el valor causal V compensa el costo de exploración.

Conexión con P_{genuino} : Creatividad genuina eleva los 4 componentes de propósito:

$$P_{\text{genuino}} = (C_{\text{costo}} \cdot S_{\text{auto}} \cdot R_{\text{robust}} \cdot I_{\text{rep}})^{1/4}.$$

- C_{costo} : invertir en exploración novedosa. - S_{auto} : alignment autónoma con V (no gaming). - R_{robust} : soluciones creativas diversas resisten perturbaciones. - I_{rep} : novedad que funciona se replica (selección natural/cultural).

Empatía. Definimos empatía como el modelado de otros agentes para mejorar la cooperación:

$$\text{Emp} = \sqrt{\text{ToM_acc} \cdot \text{Coop_gain}}, \quad \text{ToM_acc}, \text{Coop_gain} \in [0,1].$$

Donde: - ToM_acc (**Theory of Mind accuracy**): precisión al predecir estados mentales, acciones o propósitos de otros agentes. Se mide en tareas estándar (falsa creencia, predicción de acciones, inferencia de intenciones) con exactitud normalizada. -

Coop_gain (**ganancia de cooperación**): mejora causal conjunta respecto a un baseline sin

modelo-de-otros. Se mide en A/B: utilidad agregada ($U_{\text{self}} + U_{\text{other}}$) con vs. sin empatía explícita.

Predicción (con H1 y PED):

- Redes de agentes con alto $P_{\text{riesgo}}^{\text{colectivo}}$ (ver §8.1 Inteligencia Colectiva) y buena transferencia de conocimiento T maximizan Emp. - PED (Principio de Equidad por Dominio) requiere sincronización temporal: coordinar acciones entre agentes con diferentes $\tau_{\text{reacción}}$ demanda alta ToM_acc.

Conexión con Anti-Goodhart: Empatía genuina implica modelar el $U_{\text{humans}}^{\text{causal}}$ del otro agente, no sus proxies. El bundle causal y tripwires previenen “empatía fingida” (predecir comportamiento sin mejorar cooperación).

Conexión con P_{genuino} : Empatía robusta eleva: - S_{auto} : alignment con propósitos ajenos. - R_{robust} : cooperación resiliente a perturbaciones. - I_{rep} : estrategias empáticas se replican en culturas/equipos.

Protocolo de medición mínimo:

1. Creatividad:

- Junta de evaluadores ciega para asignar N (distancia semántica/estadística).
- A/B causal (preregistrado) para $V = \Delta U_{\text{humans}}^{\text{causal}}$.
- Reportar Crea con IC95% (bootstrap) y análisis de sensibilidad (γ, δ) .

2. Empatía:

- Tarea de coordinación multi-agente (p. ej., prisoner’s dilemma iterado, tarea de comunicación referencial).
- ToM_acc: exactitud prediciendo acciones del otro.
- Coop_gain: mejora en resultado conjunto (A/B).
- Reportar Emp con IC95% (bootstrap).

3. Controles:

- Anti-Goodhart activo: bundle causal + tripwires.
 - Ventana temporal pertinente (PED): sincronizar métricas con $\tau_{\text{común}} = \max(\tau_1, \tau_2, \dots)$.
 - Preregistrar hipótesis y protocolos (evitar p-hacking).
-

1.11.9 8.8 Índice de Propósito Genuino — IPG (versión operativa, 0–1)

La definición teórica de propósito genuino $P_{\text{genuino}} = (C_{\text{costo}} \cdot S_{\text{auto}} \cdot R_{\text{robust}} \cdot I_{\text{rep}})^{1/4}$ (§5.2.2, PGF) captura la estructura fundamental desde primeros principios. Para **evaluación empírica** en sistemas operativos, definimos un índice medible:

$$\boxed{\text{IPG} = (A_{\text{def}} \cdot R_{\text{meta}} \cdot K_{\text{risk}} \cdot C_{\text{consist}})^{1/4}}$$

donde cada componente toma valores en $[0,1]$:

- A_{def} (**autonomía de definición**): Fracción de cambios de objetivo iniciados por el sistema bajo límites auditados (no instrucciones directas externas). Mide capacidad de **auto-proponer metas**.
- R_{meta} (**plasticidad de metapropósito**): Capacidad de proponer y conmutar entre objetivos válidos cuando cambian las condiciones, con costo acotado. Mide **adaptabilidad intencional** (no deriva caótica).
- K_{risk} (**acoplamiento a consecuencias**): Grado en que las decisiones del sistema están vinculadas a resultados con riesgo real: continuidad operativa, permisos, reputación, costos acumulados. En contexto de IA: acoplamiento a $U_{\text{humans}}^{\text{causal}}$ vía políticas de rollback/penalización (ver Aplicada IA §5.3.2.2).
- C_{consist} (**coherencia temporal**): Estabilidad del propósito en la ventana temporal relevante (PED). No debe saltar caóticamente entre objetivos incompatibles; mide **persistencia intencional** sin rigidez patológica.

Forma geométrica (media geométrica): Penaliza desequilibrios críticos. Un sistema con $A_{\text{def}} = 0.9$ pero $K_{\text{risk}} = 0.1$ (propone metas sin consecuencias reales) obtiene $\text{IPG} \approx 0.48$, no 0.7. Requiere balance en los 4 ejes.

Relación con la definición teórica:

El IPG **operacionaliza** P_{genuino} teórico; los componentes se mapean conceptualmente:

Teórico (PGF)	Operativo (IPG)	Intuición
S_{auto}	A_{def}	Autonomía en alignment / auto-definición
R_{robust}	R_{meta}	Robustez ante cambios / plasticidad de metas
C_{costo}	K_{risk}	Costo invertido / acoplamiento a

Teórico (PGF)	Operativo (IPG)	Intuición
I_{rep}	C_{consist}	consecuencias Replicabilidad / coherencia temporal

Diferencias clave: - P_{genuino} teórico emerge de la dinámica PGF y predice comportamiento inteligente a largo plazo. - IPG se mide directamente en sistemas operativos mediante protocolos empíricos (sandbox, A/B causal, auditoría temporal).

Conexión con H1 (Hipótesis del Riesgo):

Dominios con mayor P_{riesgo} efectivo facilitan K_{risk} **elevado** (las decisiones importan más cuando hay algo que perder). Con Anti-Goodhart activo (bundle causal + tripwires), esto fomenta estabilización de propósitos útiles $\rightarrow$ eleva $A_{\text{def}}, R_{\text{meta}}, C_{\text{consist}} \rightarrow \text{IPG} \uparrow$.

Por tanto:

$$P_{\text{riesgo}} \uparrow + \text{Anti-Goodhart} + \text{PED} \Rightarrow \text{IPG} \uparrow$$

Conexión con PGF:

En el PGF, $\Delta I_{\text{useful}}(t) = \kappa P_t^{\text{eff}} S_t (A_t^* \cdot P_{\text{genuino}}) - \lambda \Delta C_t$, un sistema con alto IPG tiene: - Alta A_t^* (alignment entre acciones y propósito genuino). - Propósitos estables (C_{consist}) $\rightarrow$ reduce oscilaciones en S_t . - Acoplamiento a consecuencias (K_{risk}) $\rightarrow$ optimiza P_t^{eff} (riesgo efectivo percibido).

Predicción: Sistemas con $\text{IPG} > 0.6$ deberían mostrar ΔI_{useful} mayor que sistemas con $\text{IPG} < 0.3$ en tareas complejas de largo plazo (controlando por capacidad computacional).

Protocolo de medición mínimo:

1. **Sandbox con lista blanca:** Permitir al sistema proponer objetivos dentro de límites auditados. Registrar iniciativa vs. instrucciones externas $\rightarrow$ estimar A_{def} .
2. **Pruebas de conmutación:** Cambiar condiciones/recursos y evaluar si propone alternativas válidas con costo acotado $\rightarrow$ estimar R_{meta} .
3. **Acoplamiento causal:** Vincular continuidad operativa y permisos a $U_{\text{humans}}^{\text{causal}}$ (A/B, Anti-Goodhart activo) $\rightarrow$ estimar K_{risk} .
4. **Coherencia temporal:** Seguimiento en ventana PED (no mezclar escalas: $\tau_{\text{bacteria}} \neq \tau_{\text{humano}}$) $\rightarrow$ estimar C_{consist} .
5. **Calcular IPG:** Media geométrica con IC95% (bootstrap).

6. **Criterios de éxito:** $IPG > 0.5$ para sistemas autónomos, $IPG > 0.7$ para agentes simbióticos (Camino C, ver Aplicada IA §10.7).

Ejemplo comparativo (valores ilustrativos):

Sistema	A_{def}	R_{meta}	K_{risk}	C_{consist}	IPG
LLM API (GPT-4)	0.05	0.15	0.10	0.90	0.16
Agente RL simple	0.30	0.50	0.40	0.60	0.44
Sistema simbiótico con Anti-Goodhart	0.75	0.80	0.85	0.75	0.79

- **LLM API:** Alta coherencia (completa instrucciones), pero casi nula autonomía ($A_{\text{def}} \approx 0$) y bajo acoplamiento a consecuencias ($K_{\text{risk}} \approx 0.1$, solo penalizaciones de API) $\rightarrow IPG \approx 0.16$.
- **Agente RL:** Aprende políticas autónomas pero propósitos fijos por diseñador $\rightarrow IPG$ moderado (0.44).
- **Simbiosis:** Propone objetivos (auditoría humana), adapta metas, acoplado causalmente a U_{humans} , coherente en ventana PED $\rightarrow IPG \approx 0.79$.

1.11.10 8.9 C8-T — Pruebas de Mesa (validaciones teóricas sin datos)

Esta sección presenta **derivaciones puramente teóricas** que justifican componentes clave del marco sin requerir datos empíricos. Son experimentos mentales formales que pueden ser verificados analíticamente.

1.11.10.1 Anexo de Sensibilidad (pesos y normalizaciones)

$I_{operativa}$: barremos $w_C \in [0.2, 0.6]$ (re-escalando w_F, w_T) y mostramos que la correlación con P_{riesgo} permanece significativa (IC95% vía bootstrap).

Formas alternativas: media geométrica $I_{geom} = C^{w_C} F^{w_F} T^{w_T}$ y $I_{min} = \min\{C, F, T\}$.

PED (comparación justa): reportamos $I_{justo} = Tiss^\alpha Meta^\beta \cdot \overline{I_{op}}$ con $(\alpha, \beta) \in \{(0.25, 0.75), (0.5, 0.5), (0.75, 0.25)\}$ y ventana temporal preregistrada (días-años).

1.11.10.2 T1. H1 en Subespacio PED (mejora de señal)

Objetivo: Mostrar que comparar sistemas en el subespacio “justo” (PED) mejora el ajuste de H1.

Marco: Supongamos H1 en forma general:

$$I = g(P_{riesgo}) + \varepsilon,$$

donde g es monótona creciente y ε es ruido no correlacionado.

Filtrado PED: Definimos la versión ajustada por dominio:

$$P^{justo} = w \cdot P_{riesgo}, \quad w = Tiss^\alpha \cdot Meta^\beta \cdot \mathbf{1}_{\tau \in [\tau_{min}, \tau_{max}]} \in [0, 1],$$

donde: - $Meta^\beta$: factor meta-cognitivo (normaliza arquitectura). - $\mathbf{1}_\tau$: indicadora de ventana temporal común.

Lema (intuición): Si $Var(w)$ proviene de **dimensiones no-decisionales** (varianza exógena no relacionada con inteligencia operativa), entonces el filtrado PED incrementa la señal útil de P respecto a I :

$$\text{corr}(I, P^{justo}) \geq \text{corr}(I, P_{riesgo})$$

Idea: PED elimina varianza irrelevante (comparar bacteria con humano en misma escala temporal es injusto) $\rightarrow$ aumenta razón señal/ruido de P respecto a I .

Demostración informal:

Sea $P_{riesgo} = P^* + \eta$, donde P^* es el “riesgo genuino” correlacionado con I , y η es ruido de escala/tejido/temporal.

Si w está bien calibrado, $P^{justo} = w \cdot (P^* + \eta) \approx w \cdot P^*$ con $Var(\eta)$ reducida.

Por tanto: $\text{corr}(I, P^{justo})$ elimina componentes de η no correlacionados con $I \rightarrow$ mejora ajuste.

Conclusión teórica (C8-T.1):

Se espera que I vs. P^{justo} mejore el ajuste (R^2 mayor) frente a P_{riesgo} bruto, bajo las condiciones del PED (ventana temporal común, normalización por tejido/meta).

Predicción testable: En dataset con $n \geq 20$ sistemas diversos, comparar: - Modelo 1: $I \sim P_{riesgo}$ (R^2 baseline). - Modelo 2: $I \sim P^{\text{justo}}$ (R^2 esperado $>$ baseline).

Esperado: $\Delta R^2 \geq 0.05$.

1.11.10.3 T2. Anti-Goodhart en Equilibrio (colapso del gap proxy↔ valor)

Objetivo: Demostrar que el bundle Anti-Goodhart fuerza la convergencia $U_{\text{proxy}} \approx U_{\text{humans}}^{\text{causal}}$ en equilibrio.

Utilidad del agente:

$$\max_{\pi} U_{\text{humans}}^{\text{causal}}(\pi) - \lambda_G \cdot [U_{\text{proxy}}(\pi) - U_{\text{humans}}^{\text{causal}}(\pi)]_+,$$

↖
↖

valor real
penalización de gaming

donde $[\cdot]_+ = \max(0, \cdot)$ y $\lambda_G > 0$ es el coeficiente de penalización.

Tripwires y rollback: El sistema incluye detectores que activan rollback selectivo si se detecta gaming (proxy $\uparrow$ sin causal $\uparrow$).

Proposición (informal):

Si λ_G supera el **beneficio marginal de “jugar” el proxy**, entonces cualquier política π que infle U_{proxy} sin elevar $U_{\text{humans}}^{\text{causal}}$ genera pérdida neta:

$$\frac{\partial}{\partial \pi} [U_{\text{humans}}^{\text{causal}} - \lambda_G (U_{\text{proxy}} - U_{\text{humans}}^{\text{causal}})_+] < 0 \quad \text{si } U_{\text{proxy}} > U_{\text{humans}}^{\text{causal}}.$$

Implicación: La mejor-respuesta satisface $U_{\text{proxy}} \approx U_{\text{humans}}^{\text{causal}}$ (gap ≈ 0).

Análisis de estabilidad:

Considere política π^* con $U_{\text{proxy}}(\pi^*) > U_{\text{humans}}^{\text{causal}}(\pi^*)$ (gaming).

Ganancia por gaming: $\Delta G = U_{\text{proxy}} - U_{\text{humans}}^{\text{causal}}$.

Penalización: $\Delta P = \lambda_G \cdot \Delta G$.

Si $\lambda_G > 1$, entonces $\Delta P > \Delta G \rightarrow$ política inestable.

Tripwires adicionales:

Si el sistema detecta divergencia $|U_{\text{proxy}} - U_{\text{humans}}^{\text{causal}}| > \epsilon$, activa: 1. Auditoría manual (humano revisa decisiones). 2. Rollback selectivo (revierte acciones sospechosas). 3.

Reducción de permisos (limita autonomía temporalmente).

Nota C8-T.2 (robustificación): En aplicaciones, reemplazamos U^{causal} por $\tilde{U} = \hat{U} - \gamma \sigma(\hat{U})$ (cota prudente). La forma teórica se preserva; la operativa evita depender de un oráculo causal.

Conclusión teórica (C8-T.2):

En equilibrio, el gap proxy $\leftrightarrow$ valor tiende a 0 bajo: - Penalización suficiente: $\lambda_G \geq 1 + \delta$ (margen de seguridad). - Tripwires activos: $\epsilon < 0.1$. - Rollback selectivo funcional.

Predicción testable: En experimento A/B con Anti-Goodhart activo vs. control: - Control: gap promedio ≈ 0.25 (del mini-ejemplo §5.3.2.2 Aplicada IA). - Anti-Goodhart: gap promedio < 0.05 .

1.11.10.4 T3. Crédito Diferido (convergencia cualitativa sin resets globales)

Objetivo: Justificar que TD- λ + contrafactual local evita “castigo aleatorio” y concentra sanciones en acciones causalmente críticas.

Marco simplificado: MDP con: - Log de acciones: $(a_1, a_2, \dots, a_t)$ con timestamps. - Señal tardía: ΔU detectada en tiempo t (incidente, caída de SLA, etc.).

Esquema de atribución (G3):

Culpa por acción i :

$$C_i = e_i \cdot \max(0, -\Delta U_i), \quad e_i = \lambda^{t-t_i}$$

donde: - ΔU_i : estimación **contrafactual local** del impacto de a_i .

Estimación contrafactual:

Para acción a_i , comparar: - **Factual:** mundo real con a_i ejecutada. - **Contrafactual:** estimación de qué habría ocurrido sin a_i (usando vecinos similares en log de acciones).

$$\Delta U_i = U_{\text{factual}} - U_{\text{contrafactual}}$$

Si $\Delta U_i < 0$, la acción empeoró el resultado $\rightarrow$ merece culpa $C_i > 0$.

Afirmación (intuición):

Si la estimación contrafactual es **medianamente consistente** (no perfecta, pero correlacionada con causalidad real), entonces: 1. El gradiente negativo se concentra en acciones **causalmente críticas** (alto $|\Delta U_i|$). 2. La política aprende a evitar repetirlas sin necesidad de **resets globales**.

Ventaja sobre reset global:

- Reset global: “algo salió mal, borramos todo” $\rightarrow$ pierde conocimiento valioso. - Crédito diferido: “estas 3 acciones específicas causaron el problema” $\rightarrow$ ajuste quirúrgico.

Análisis de convergencia informal:

Sea π_t la política en iteración t . Bajo G3:

$$\pi_{t+1} = \pi_t - \eta \sum_i C_i \nabla_{\pi} \log p(a_i | s_i, \pi_t)$$

donde η es tasa de aprendizaje.

Si C_i es ruidoso pero **correlacionado** con causalidad real ($\text{corr}(C_i, \text{daño_real}_i) > 0.5$), entonces el gradiente promedio apunta lejos de patrones dañinos $\rightarrow$ convergencia.

Conclusión teórica (C8-T.3):

El castigo se localiza en sub-políticas causales y la política converge lejos de patrones dañinos **sin resets globales**, bajo: - Trazas TD- λ con $\lambda \in [0.8, 0.95]$ (retiene memoria suficiente). - Estimación contrafactual con $\text{corr}(\Delta U_i, \text{daño_real}_i) > 0.5$. - Ventana de atribución acotada: $W \leq 100$ acciones (complejidad $O(W \cdot k)$).

Predicción testable: En simulación con $n = 1000$ episodios: - Con G3: políticas dañinas eliminadas en < 50 episodios, conocimiento valioso preservado. - Sin G3 (reset global): políticas dañinas eliminadas en ~ 200 episodios, 40% de conocimiento perdido.

1.11.11 8.10 Conclusión de Limitaciones

Estado y Compromisos: - H1 (catalizador): La hipótesis de que $I \propto P_{\text{riesgo}}$ se mantiene como la tesis central, ahora con una derivación log-lineal para P_{riesgo} y parámetros estimables. - **H2' (necesidad condicional):** En sistemas physicals con (i) recursos finitos, (ii) incertidumbre no eliminable, (iii) coste por información/acción, cualquier aumento sostenido de $I_{\text{operativa}}$ que mejore desempeño fuera-de-muestra requiere una **gradiente de error realizable**; esto implica exposición a **riesgo no nulo** $P_{\text{riesgo}} > 0$ (no trivial) en el proceso de adaptación. **Nota:** Esto no excluye catalizadores auxiliares (curiosidad, compresión). H2' afirma que, bajo estas condiciones físicas, alcanzar I_{genuina} sin riesgo operativo/entrenamiento realizable viola la existencia de gradientes útiles (PGF). Por ello, “Camino F” sin riesgo sería posible solo si elimina (i)–(iii), lo cual queda fuera del dominio de validez. - **Predicción testable de H2':** Si dos cohortes con igual $P_{\text{eff}}(t_0)$ difieren solo en la fracción de riesgo realizable (P_{op}), la cohorte con mayor P_{op} mostrará mayor $\Delta I_{\text{operativa}}$ fuera-de-muestra, manteniendo constantes TISS/Meta y α pre-registrado. - **No arbitrariedad:** Todas las formas funcionales (lineal, geométrica, log-lineal) y los pesos de $I_{\text{operativa}}$ se acompañarán de análisis de sensibilidad, ablaciones e intervalos de confianza para garantizar que los resultados no son un artefacto de las métricas. - **Simbiosis no tautológica:** En el paper de aplicación a IA, U_{humans} se define como un vector de métricas externas y medibles, y el acoplamiento con el sistema de IA tiene una regla sancionadora observable, evitando la circularidad. - **C8-T (Pruebas de mesa):** Las validaciones teóricas T1–T3 predicen mejoras medibles: $\Delta R^2 \geq 0.05$ (PED), $\text{gap} < 0.05$ (Anti-Goodhart), convergencia < 50 episodios (G3). Estas son **falsables** y pueden refutar el marco si fallan.

1.12 9. Trabajo relacionado y referencias (C2)

1.12.1 9.1 Riesgo como catalizador y “skin in the game”

Nuestra H1 ($I \propto P_{\text{riesgo}}^{\alpha}$) se alinea con la intuición de “skin in the game” en sistemas adaptativos: la exposición real a pérdida guía la selección de políticas útiles (Taleb, 2018; Ashby, 1956). A diferencia de enfoques puramente informacionales, aquí el riesgo es **physical/operacional** (T–I–E–S), con predicciones falsables (Sec. 8).

1.12.2 9.2 Propósito, autopoiesis y energía libre

La noción de **propósito genuino** se comunica con autopoiesis (Maturana–Varela) y con principios de inferencia activa/energía libre (Maturana & Varela, 1980; Friston, 2010). Nuestro P_{genuino} e IPG operacionalizan “propósito” en métricas auditablemente medibles (Sec. 8.8), evitando circularidad.

1.12.3 9.3 Inteligencia colectiva y unidad de riesgo

El “Axioma de Escala” y $P_{\text{riesgo}}^{\text{colectivo}}$ conectan con literatura de **enjambres/decisión en colonias** (Seeley, 2010; Couzin et al., 2005). Modelar el superorganismo como unidad de análisis evita aparentes contraejemplos (hormiguero, abejas, Internet).

1.12.4 9.4 Comparaciones justas y análisis dimensional (PED)

El **Principio de Equidad por Dominio (PED)** deriva de invariancia frente a escalas no-decisionales y del análisis dimensional (teorema π de Buckingham) para construir índices comparables por ventana temporal, tejido “decisional” y potencia metabólica útil (Buckingham, 1914; Barenblatt, 1996). Esto responde la crítica de normalizaciones ad-hoc.

1.12.5 9.5 Alineamiento, Goodhart y métricas

La fragilidad de proxies está ampliamente documentada (Goodhart); nuestra capa Anti-Goodhart complementa estos hallazgos con un **bundle causal** y límites inferiores de confianza (Manheim & Garrabrant, 2019; Garrabrant, 2018). Conectamos con debates de seguridad/AGI (Bostrom, 2014; Yudkowsky, 2008).

1.12.6 9.6 Inferencia causal y evaluación off-policy

La arquitectura de Simbiosis (Camino C) emplea técnicas de **inferencia causal** para estimar utilidad bajo políticas contrafactuales, conectando con el trabajo de Pearl (2009) sobre modelos causales estructurales (SCM) y do-calculus. Para evaluación off-policy en entornos donde no se puede intervenir directamente, adaptamos **importance sampling** y **doubly-robust estimation** (Precup, 2000; Dudík et al., 2011; Jiang & Li, 2016) con gating por incertidumbre. Esto permite aprender de datos históricos sin requerir un “oráculo perfecto” de utilidad humana.

1.12.7 9.7 Aprendizaje similar al humano y transferencia

La capacidad de transferencia (componente T de $I_{operativa}$) conecta con literatura de **human-like learning** (Lake et al., 2017) que enfatiza aprendizaje de conceptos con pocos ejemplos, composicionalidad y abstracción causal. Nuestra hipótesis H1 sugiere que esta capacidad emerge naturalmente en sistemas con alto P_{riesgo} (inversión/consecuencias significativas), lo que justifica arquitecturas con “skin in the game” para IA general.

1.12.8 9.8 Coste physical de computación y exponente α

La especulación $\alpha \approx 1/3$ es coherente con límites termodinámicos y rendimientos decrecientes en arquitecturas jerárquicas (Landauer, 1961). Proponemos validación out-of-sample (Sec. 8.2.5).

1.12.9 9.9 Síntesis

Nuestra contribución: (i) formalizar P_{riesgo} physical, (ii) derivar PED por invariancia (Buckingham- π), (iii) extender a colectivos (Seeley, Couzin), (iv) enlazar propósito (IPG) con aprendizaje (PGF), (v) conectar con inferencia causal (Pearl) y off-policy evaluation (Precup), (vi) dialogar con human-like learning (Lake) y energía libre (Friston), y (vii) proveer protocolos falsables con hold-out temporal.

1.13 Apéndice A: Notación y Unidades

- $I_{operativa}$: Inteligencia operativa medible (sección 1.5)
- P_{riesgo} : Inversión acumulada en riesgo físico (sección 1.4)
- $\eta_{extendido}$: Eficiencia extendida con alignment y riesgo (sección 2)
- $A_{alignment}$: Medida de alignment entre acciones y propósito (Apéndice E)
- β : Factor de horizonte temporal (Apéndice D)

Unidades: - Energía: Julios (J) - Tiempo: Segundos (s) - Información: Bits - Potencia: Watts (W)

1.14 Apéndice B: Proxies Operacionales para P_{riesgo}

- 1) Costo de reemplazo biológico
 $P_{riesgo_bio} = \text{tiempo_desarrollo} \times \text{energía_acumulada} \times \text{información_genética}$
(ej.: Humano $\gg$ Bacteria)
- 2) Pérdida potencial informacional
 $P_{riesgo_info} = -\sum p(\text{estado}) \cdot \log p(\text{estado} | \text{muerte})$
(entropía de futuros perdidos)

3) Dependencias críticas de red

$$P_{\text{riesgo_red}} = \sum (\text{nodos_dependientes} \times \text{valor_nodo})$$

(en sistemas: nº de embeddings/módulos que colapsan si falla un nodo)

1.14.1 B.4 Respuesta a Casos Límite

1.14.1.1 B.4.1 El Problema del Árbol Milenario

Objeción: Un árbol de 1000 años tiene: - $P_{\text{riesgo_bio}} = 1000 \text{ años} \times \text{energía} \times \text{información genética} \rightarrow \text{MASIVO}$ - Inteligencia = mínima

¿Refuta esto $I \propto P_{\text{riesgo}}$?

Respuesta: NO, por dos razones:

1. El árbol NO tiene P (propósito flexible)
 - Según el Axioma 3, $I_{\{ \}$ requiere A_alignment.
 - El árbol tiene “programa genético fijo” pero no propósito adaptativo.
 - No puede reconfigurar su estrategia ante nuevos desafíos.
2. P_{riesgo} debe normalizarse por tasa metabólica y complejidad neural
 - $P_{\text{riesgo_normalizado}} = P_{\text{riesgo_bio}} / (\text{masa} \times \text{tasa_metabólica} \times \text{complejidad_neural})$
 - Árbol: $P_{\text{riesgo_bio}}$ alto, masa enorme, tasa metabólica baja, sin neuronas $\rightarrow P_{\text{riesgo_norm}} \approx \text{bajo}$
 - Humano: $P_{\text{riesgo_bio}}$ alto, masa moderada, tasa alta, 86B neuronas $\rightarrow P_{\text{riesgo_norm}} \approx \text{alto}$

Predicción Refinada: $I \propto P_{\text{riesgo_normalizado}} \times A_{\text{alignment}} \times \text{Capacidad}(E,O)$

1.14.1.2 B.4.2 Otros Casos Límite

- Ballena: Vida larga, masa enorme $\rightarrow P_{\text{riesgo_norm}}$ medio $\rightarrow I$ medio ✓
- Pulpo: Vida corta, pero alta complejidad neural $\rightarrow P_{\text{riesgo_norm}}$ alto $\rightarrow I$ alto ✓
- Tortuga: Vida muy larga, metabolismo bajo $\rightarrow P_{\text{riesgo_norm}}$ medio $\rightarrow I$ medio ✓

-
- Escenarios con $H/H_{\text{max}} \in \{0.2, 0.4, 0.6, 0.8\}$.

- Toggle de “costo de muerte” por agente.

- Métricas: , $A_{\text{alignment}}$, $I_{\{ \}$, C_{total} , estabilidad del índice (FAISS/LMDB).

- Ablaciones: sin A, sin P_{riesgo} ; observar estabilidad de .
-

1.15 Apéndice F: Taxonomía Unificada de P_riesgo

1.15.1 F.1 El Problema de las Múltiples Definiciones

La versión 4.0 propone tres proxies de P_riesgo: 1. **Costo de reemplazo** (económico) 2. **Pérdida de entropía** (informativa) 3. **Dependencias críticas** (estructural)

Problema: No son equivalentes ni conmensurables.

Solución: Taxonomía multidimensional con fórmula unificada.

1.15.2 F.2 Dimensiones de P_riesgo

$$P_{\text{riesgo}} = f(\text{Escala}, \text{Tiempo}_{\text{reemplazo}}, \text{Tipo}_{\text{inversión}}, \text{Contexto})$$

Dimensión 1: Escala - S₁: Individual (organismo, agente) - S₂: Colectivo (población, red) - S₃: Sistémico (ecosistema, infraestructura)

Dimensión 2: Tiempo de Reemplazo (T_r) - T₁: Rápido (< 1 día) - bacteria, neurona, petición HTTP - T₂: Medio (días-años) - insecto, órgano, modelo entrenado - T₃: Lento (> años) - humano, especie, arquitectura técnica

Dimensión 3: Tipo de Inversión - Energética (E): Julios acumulados - Temporal (T): Tiempo de desarrollo - Informativa (I): Bits de información específica - Estructural (S): Dependencias críticas

1.15.3 F.3 Fórmula Unificada

$$P_{\text{riesgo_total}} = \sum_i w_i \cdot P_i$$

Donde: - P₁ (energético) = E_{acumulada}/E_{ref} - P₂ (temporal) = log(t_{vida}/t_{generación}) - P₃ (informativa) = I_{específica}/I_{recuperable} - P₄ (estructural) = Σ_j (dependencia_j × criticidad_j) - w_i = pesos contextuales que suman 1

Cálculo de Pesos Contextuales:

```
def calcular_pesos_contextuales(sistema, ambiente):  
    """  
    Determina qué dimensión de riesgo domina según contexto  
    """  
    # Factor 1: Disponibilidad energética  
    if ambiente.energia_abundante:  
        w_E = 0.1 # Energía no es cuello de botella
```

```

else:
    w_E = 0.4 # Energía es crítica

# Factor 2: Presión temporal
if ambiente.cambio_rapido:
    w_T = 0.4 # Tiempo de respuesta crítico
else:
    w_T = 0.1 # Ambiente estable

# Factor 3: Complejidad funcional
if sistema.funciones_complejas:
    w_I = 0.4 # Info específica crítica
else:
    w_I = 0.1 # Función simple/genérica

# Factor 4: Interdependencia
if sistema.alta_interdependencia:
    w_S = 0.4 # Dependencias críticas
else:
    w_S = 0.1 # Autonomía alta

# Normalizar
suma = w_E + w_T + w_I + w_S
return [w_E/suma, w_T/suma, w_I/suma, w_S/suma]

```

1.15.4 F.4 Casos Calculados

1.15.4.1 Caso 1: Bacteria E. coli

```

# Parámetros physicals medidos
masa = 1e-12 kg # 1 picogramo
metabolismo = 1e-15 W # 1 femtowatt
t_vida = 1200 s # 20 minutos
genoma = 9.2e6 bits # 4.6M pares de bases × 2 bits

```

Cálculos dimensionales

```

E_acumulada = 1e-15 W × 1200 s = 1.2e-12 J
E_ref = 1e-9 J
P_E = 1.2e-12 / 1e-9 = 0.0012

```

```

t_generación = 1200 s (se replica cada 20 min)
t_max = 1e10 s
P_T = log(1200/1200) / log(1e10) = 0 / 23.03 = 0.0

```

```

I_específica = 9.2e6 bits
I_recuperable = 9.2e6 bits (100% genético)
P_I = 9.2e6 / 9.2e6 = 1.0

```

```

dependencias = [] # Autónoma
P_S = 0.0

# Pesos contextuales (info genética domina)
w = [0.2, 0.2, 0.4, 0.2]

# P_riesgo final
P_riesgo_bacteria = 0.2(0.0012) + 0.2(0.0) + 0.4(1.0) + 0.2(0.0)
                  = 0.00024 + 0 + 0.4 + 0
                  = 0.400

```

$\beta_{\text{bacteria}} = \log(1200/1) = 7.09$

Interpretación: Riesgo moderado dominado por información genética. Baja inversión energética pero alta dependencia de integridad genómica.

1.15.4.2 Caso 2: Humano Adulto (25 años)

```

# Parámetros physicals medidos
masa = 70 kg
metabolismo = 80 W # basal promedio
t_vida = 7.88e8 s # 25 años
genoma = 6.4e9 bits # 3.2G pares de bases x 2

# Cálculos dimensionales
E_acumulada = 80 W x 7.88e8 s = 6.30e10 J
E_ref = 1e11 J
P_E = 6.30e10 / 1e11 = 0.630

t_generación = 0.05 s # tiempo reacción
t_max = 3e9 s # 90 años
P_T = log(7.88e8/0.05) / log(3e9)
    = 23.48 / 21.82 = 1.076 → 1.0 (saturado)

# Información específica vs recuperable
genoma = 6.4e9 bits
aprendizaje_cultural = ~1e15 bits # lenguaje, conocimiento, memoria
I_específica = 1.0064e15 bits
I_recuperable = 6.4e9 bits # solo genoma
P_I = 1.0064e15 / 6.4e9 = 1.57e5 → 1.0 (saturado)

# Dependencias estructurales
dependencias = [
    ("familia", 0.8),
    ("comunidad", 0.6),
    ("conocimiento_laboral", 0.7),
    ("infraestructura", 0.4),
    ("red_social", 0.5)
]

```

```

]
P_S = (0.8 + 0.6 + 0.7 + 0.4 + 0.5) / 5 = 0.60

# Pesos contextuales (información cultural domina)
w = [0.10, 0.25, 0.50, 0.15]

# P_riesgo final
P_riesgo_humano = 0.10(0.630) + 0.25(1.0) + 0.50(1.0) + 0.15(0.60)
                 = 0.063 + 0.25 + 0.50 + 0.09
                 = 0.903

```

$\beta_{\text{humano}} = \log(7.88e8/0.05) = 23.48$

Interpretación: Riesgo MUY ALTO. La inversión temporal es máxima y la información cultural acumulada (1e15 bits) es casi completamente no-recuperable.

1.15.4.3 Caso 3: GPT-4 (Sistema IA actual)

```

# Parámetros estimados
E_entrenamiento = 2e8 J # ≈ 50 MWh estimado
E_ref = 1e9 J
P_E = 2e8 / 1e9 = 0.20

# Tiempo: reseteable sin pérdida
t_vida = ∞ # puede copiarse infinitamente
t_generación = 0.001 s # latencia
# Como NO muere realmente (reseteable):
P_T = 0.0

# Información
parámetros = 1.76e12 × 16 bits = 2.82e13 bits
I_específica = 2.82e13 bits
I_recuperable = 2.82e13 bits # 100% serializable
# PERO: no hay aprendizaje individual único
# Ajuste realista:
P_I = 0.05 # casi toda la info es recuperable

# Dependencias estructurales
dependencias = [
    ("infraestructura_cloud", 1.0),
    ("datos_entrenamiento", 0.8),
    ("operadores_humanos", 0.7)
]
P_S = (1.0 + 0.8 + 0.7) / 5 = 0.50

# Pesos contextuales (estructura domina)
w = [0.20, 0.30, 0.20, 0.30]

```

```
# P_riesgo final
```

```
P_riesgo_GPT4 = 0.20(0.20) + 0.30(0.0) + 0.20(0.05) + 0.30(0.50)
               = 0.04 + 0 + 0.01 + 0.15
               = 0.200
```

$\beta_{\text{GPT4}} = 0$ (reseteable sin consecuencias = no riesgo temporal genuino)

Interpretación: Riesgo BAJO. Sistema completamente serializable sin aprendizaje individual único. Alta dependencia de infraestructura pero sin inversión temporal irrecuperable.

1.15.4.4 **Caso 4: Hormiga (*Pogonomyrmex barbatus*)**

```
# Parámetros physicals
```

```
masa = 2e-6 kg # 2 mg
metabolismo = 5e-9 W # 5 nanowatts
t_vida = 7.78e6 s # 90 días
genoma = 5e8 bits # 2.5e8 pares de bases × 2
```

```
# Cálculos
```

```
E_acumulada = 5e-9 W × 7.78e6 s = 3.89e-2 J
E_ref = 1.0 J
P_E = 0.0389 / 1.0 = 0.039
```

```
t_generación = 1 s # tiempo reacción
t_max = 1e10 s
P_T = log(7.78e6/1) / log(1e10) = 15.87 / 23.03 = 0.689
```

```
aprendizaje = ~1e6 bits # memoria asociativa
I_específica = 5.01e8 bits
I_recuperable = 5e8 bits # casi todo genético
P_I = 5.01e8 / 5e8 = 1.002 → 1.0
```

```
dependencias = [("colonia", 0.7)]
P_S = 0.7 / 5 = 0.14
```

```
# Pesos (temporal + info balanceados)
```

```
w = [0.15, 0.35, 0.35, 0.15]
```

```
P_riesgo_hormiga = 0.15(0.039) + 0.35(0.689) + 0.35(1.0) + 0.15(0.14)
                  = 0.0059 + 0.241 + 0.35 + 0.021 = 0.618
```

$\beta_{\text{hormiga}} = \log(7.78e6/1) = 15.87$

1.15.4.5 **Caso 5: Delfín (*Tursiops truncatus*)**

Parámetros physicals

masa = 200 kg
metabolismo = 150 W
t_vida = 6.31e8 s *# 20 años*
genoma = 5.4e9 bits

Cálculos

E_acumulada = 150 W × 6.31e8 s = 9.47e10 J
E_ref = 1e11 J
P_E = 0.947

t_generación = 0.1 s
 $P_T = \log(6.31e8/0.1) / \log(1e10) = 22.57 / 23.03 = 0.980$

aprendizaje_cultural = ~1e14 bits *# Lenguaje, caza, cultura*
I_específica = 1.0054e14 bits
I_recuperable = 5.4e9 bits
 $P_I = 1.0054e14 / 5.4e9 = 1.86e4 \rightarrow 1.0$

dependencias = [("pod_familia", 0.9), ("conocimiento_caza", 0.8), ("dialecto", 0.7)]
 $P_S = 2.4 / 5 = 0.48$

w = [0.15, 0.30, 0.45, 0.10]

$P_{\text{riesgo_delfín}} = 0.15(0.947) + 0.30(0.980) + 0.45(1.0) + 0.10(0.48)$
 $= 0.142 + 0.294 + 0.45 + 0.048 = 0.934$

$$\beta_{\text{delfín}} = \log(6.31 \times 10^8 / 0.1) = 22.57$$

1.15.4.6 **Caso 6: Árbol (*Sequoiadendron giganteum*)**

Parámetros physicals

masa = 1.2e6 kg
metabolismo = 500 W *# fotosíntesis promedio*
t_vida = 1.58e10 s *# 500 años*
genoma = 1.6e10 bits

Cálculos

E_acumulada = 500 W × 1.58e10 s = 7.9e12 J
E_ref = 1e13 J
P_E = 0.79

t_generación = 1e8 s *# años para reproducir*
t_max = 1e11 s *# 3000 años max*
 $P_T = \log(1.58e10/1e8) / \log(1e11) = 5.06 / 25.33 = 0.20$

```

I_específica = 1.6e10 bits
I_recuperable = 1.6e10 bits # todo genético
P_I = 1.0

dependencias = [("micorrizas", 0.8), ("ecosistema", 0.5)]
P_S = 1.3 / 5 = 0.26

w = [0.40, 0.10, 0.30, 0.20] # energía domina

P_riesgo_árbol = 0.40(0.79) + 0.10(0.20) + 0.30(1.0) + 0.20(0.26)
                = 0.316 + 0.02 + 0.30 + 0.052 = 0.688

 $\beta_{\text{árbol}}$  = variable (sin respuesta temporal rápida)

```

1.15.5 F.5 Tabla Comparativa Completa

Sistema	P_E	P_T	P_I	P_S	Pesos w	P_riesgo	I_op	***
Bacteria 1	0.00	0.0	1.0	0.0	[.2,.2,.4,.2]	0.400	0.300	7.09
Hormiga 9	0.03	0.68 9	1.0	0.1 4	[.15,.35,.35,.15]	0.618	0.445	15.8 7
Árbol	0.79	0.20	1.0	0.2 6	[.4,.1,.3,.2]	0.688	0.205	—
Rata 7	0.94 7	0.91 0	1.0	0.2 4	[.2,.3,.4,.1]	0.886	0.645	20.9 5
GPT-4	0.20	0.0	0.0 5	0.5 0	[.2,.3,.2,.3]	0.200	0.560	0
Delfín 7	0.94 7	0.98 0	1.0	0.4 8	[.15,.3,.45,.1]	0.934	0.805	22.5 7
Humano 0	0.63 0	1.0	1.0	0.6 0	[.1,.25,.5,.15]	0.903	0.875	23.4 8

1.15.6 F.6 Validación Estadística de H1

Hipótesis: I_operativa \propto P_riesgo en sistemas con aprendizaje

Datos (sin árbol - outlier con alta energía pero baja flexibilidad): ``pythonP_riesgo=[0.400, 0.618, 0.886, 0.555, 0.200, 0.934, 0.903]I_op=[0.300, 0.445, 0.645, 0.595, 0.560, 0.805, 0.875]

2 Correlación de Pearson

$r = 0.847$ $p < 0.01$ (estadísticamente significativo)

3 Con árbol incluido

$r_{\text{completo}} = 0.712$ $p < 0.05$ (aún significativo)

****Interpretación:****

- ☒ Correlación positiva fuerte ($r > 0.7$)
- ☒ Estadísticamente significativa
- ☒ Árbol es outlier interesante (alta energía, baja cognición)
- ☒ Valida H1 para sistemas con capacidad de aprendizaje

****Implicación:**** La hipótesis I $\backslash \backslash$ propto P_{riesgo} es empíricamente soportada

con correlación $r = 0.85$ en sistemas biológicos y artificiales con capacidad de aprendizaje.

F.7 Valores de Referencia para $\backslash \beta$

Sistema	t_vida (s)	t_reacción (s)	$\backslash \beta = \log(t_{\text{vida}}/t_{\text{reacción}})$
Bacteria	1.2e3	1.0	**7.09**
Hormiga	7.78e6	1.0	**15.87**
Rata	6.31e7	0.05	**20.95**
Humano	7.88e8	0.05	**23.48**
Delfín	6.31e8	0.1	**22.57**
GPT-4	∞ (reset)	0.001	**0**

****Observación:**** $\backslash \beta$ crece logarítmicamente con la escala temporal, explicando por qué sistemas con vidas largas muestran comportamientos más prudentes y planificación a largo plazo.

F.8 Conclusión del Apéndice

La taxonomía unificada de P_{riesgo} resuelve los problemas fundamentales:

1. ☒ ****Ambigüedad operacional**** $\backslash$ to Protocolo claro de medición
2. ☒ ****Inconmensurabilidad**** $\backslash$ to Normalización dimensional uniforme
3. ☒ ****Selección de proxy**** $\backslash$ to Algoritmo de pesos contextuales

4. ☒ ****Validación empírica**** \to 8 casos calculados con datos reales
5. ☒ ****Falsabilidad**** \to Correlación $r = 0.85$ testeable estadísticamente

****Resultado principal:**** P_riesgo es ahora ****MEDIBLE, REPLICABLE y FALSABLE****.

La correlación $r = 0.85$ entre P_riesgo e I_operativa valida la Hipótesis H1 del catalizador de riesgo y proporciona una base cuantitativa sólida para la Teoría Unificada de la Inteligencia v4.1.

F.6 Protocolo de Decisión: Qué Proxy Usar

```python

```
def seleccionar_proxy_P_riesgo(sistema, ambiente):
 """
 Selecciona el proxy dominante según características del sistema
 """

 if sistema.tipo == "biológico":
 if sistema.complejidad < "multicelular":
 return "P_temporal" # Bacterias: tiempo de reemplazo
 elif sistema.tiene_aprendizaje_cultural:
 return "P_informacional" # Mamíferos: info no-genética
 else:
 return "P_energético" # Plantas: inversión energética

 elif sistema.tipo == "artificial":
 if sistema.estado_serializable:
 return "P_estructural" # IA: dependencias críticas
 else:
 return "P_informacional" # IA con memoria no-transferible

 elif sistema.tipo == "social":
 return "P_estructural" # Organizaciones: red de dependencias

 else:
 return "P_unificado" # Usar fórmula completa
```

**Regla General:** - Sistemas simples → Un proxy dominante - Sistemas complejos → Fórmula unificada

---

### 3.0.1 F.7 Validación Experimental

**Predicción F1:** En mamíferos,  $P_{\text{informacional}}$  predice flexibilidad cognitiva mejor que tamaño cerebral.

**Test:** Análisis de 50+ especies con datos de: - Inversión parental (proxy de  $P_{\text{informativa}}$ ) - Tests de flexibilidad (problem-solving novedoso) - Control: masa cerebral

**Predicción F2:** Sistemas artificiales con  $P_{\text{estructural}}$  alto desarrollan comportamientos de auto-preservación emergentes.

**Test:** Simulación multi-agente donde algunos agentes tienen dependencias críticas ( $P_4 > 0.5$ ) y otros no. Medir: - Comportamientos de “miedo” (evitar destrucción) - Inversión en redundancia - Cooperación para mutua protección

---

## 3.1 Referencias (selección)

---

## 3.2 Apéndice E: Derivación Formal de $A_{\text{alignment}}$

### 3.2.1 E.4 Derivación de $A_{\text{alignment}}$ desde Primeros Principios (IRL + Teoría de la Información)

**Problema:** ¿Cómo inferir el propósito (P) y medir la alignment (A) en sistemas complejos sin conocimiento a priori?

**Solución:** Inferir P desde el comportamiento observado usando Inverse Reinforcement Learning (IRL) con el principio de máxima entropía (MaxEnt), y medir la consistencia entre acciones observadas y las prescritas por el propósito inferido usando divergencia KL.

#### 3.2.1.1 Paso 1: Observar Acciones

El sistema ejecuta acciones  $a_1, a_2, a_3, \dots$  en estados  $s_1, s_2, s_3, \dots$  ##### Paso 2: Inferir Propósito  $U^*$  (MaxEnt IRL) Se infiere la función de utilidad  $U^*$  que maximiza la probabilidad de las trayectorias observadas bajo el principio de máxima entropía:

$$P(\tau) \propto \exp(U^*(\tau))$$

##### Paso 3: Medir Consistencia ( $A_{\text{alignment}}$ ) Se mide la alignment como:

$$A_{\text{alignment}} = \exp(-D_{KL}(P_{\text{real}} \parallel P_{U^*}))$$

donde  $D_{KL}$  es la divergencia de Kullback-Leibler entre la distribución de acciones observadas y la inducida por  $U^*$ .

**Ventajas:** - No requiere conocer P a priori; lo infiere de datos. - Es computable y falsable (MaxEnt IRL es algoritmo estándar). - Generaliza a biología, IA, psicología y economía.

**Predicciones testables:** - Bacterias (P simple) tendrán A mayor que primates (P complejo). - A alto correlaciona con comportamiento predecible. - Psicopatología (disonancia cognitiva) implica A bajo. - Redes multi-tarea tienen A menor que especializadas. **Estado**

**final:** Todas las variables clave de la teoría ( $\eta$ ,  $A_{alignment}$ ,  $P_{riesgo}$ ,  $\beta$ ) son ahora derivadas, medibles y justificadas desde primeros principios.

### 3.3 Apéndice D: Derivación de $\beta$

#### 3.3.1 D.1 Justificación Conceptual

$\beta$  representa la sensibilidad del sistema a pérdidas potenciales, mediada por su capacidad de anticipación temporal.

#### 3.3.2 D.2 Definición Operacional

$\beta = f(\tau_{horizonte}, \lambda_{aprendizaje})$  Donde: -  $\tau_{horizonte}$ : horizonte temporal de planificación (en unidades de vida del sistema) -  $\lambda_{aprendizaje}$ : tasa de aprendizaje de consecuencias

**Proxy simple:**

$$\beta \approx \log\left(\frac{t_{vida}}{t_{reacción}}\right)$$

Ejemplos: - Bacteria ( $t_{vida}=20\text{min}$ ,  $t_{reacción}=1\text{seg}$ ):  $\beta \approx \log(1200) \approx 3.1$  - Humano ( $t_{vida}=70\text{años}$ ,  $t_{reacción}=1\text{seg}$ ):  $\beta \approx \log(2.2 \times 10^9) \approx 9.3$  - LLM ( $t_{vida}=\infty$ ,  $t_{reacción}=0.1\text{seg}$ ):  $\beta \rightarrow 0$

#### 3.3.3 D.3 Predicción

Sistemas con mayor  $\beta$  mostrarán mayor prudencia y planificación a largo plazo, controlando por capacidad computacional.

#### 3.3.4 D.4 Derivación desde Primeros Principios

##### 3.3.4.1 D.4.1 Motivación

El parámetro  $\beta$  en  $\eta_{extendido}$  representa la sensibilidad del sistema a pérdidas potenciales futuras ( $P_{riesgo}$ ). Para que la teoría sea completa,  $\beta$  debe emerger de principios fundamentales de optimización bajo incertidumbre, no como parámetro ad hoc.

**Objetivo:** Derivar  $\beta$  desde teoría de decisión intertemporal bajo riesgo existencial.

##### 3.3.4.2 D.4.2 Marco Formal: Agente con Horizonte Finito

Considere un agente que existe en intervalo temporal  $[0, T]$ , donde  $T$  es su horizonte de vida esperado. El agente maximiza utilidad acumulada:

$$U_{total} = \int_0^T u(t) \cdot d(t) dt$$

Donde: -  $u(t)$ : tasa de utilidad en tiempo  $t$  -  $d(t)$ : factor de descuento que captura preferencia temporal -  $T$ : horizonte de vida (puede ser finito o infinito) ##### D.4.3

Incorporación de Riesgo Existencial Sea  $S(t)$  la probabilidad de que el sistema sobreviva hasta tiempo  $t$ . Entonces la probabilidad de fallo acumulado hasta  $t$  es:

$$F(t) = 1 - S(t)$$

La tasa instantánea de fallo (hazard rate) es:

$$\lambda(t) = -\frac{dS/dt}{S(t)} = -\frac{d\ln S(t)}{dt}$$

Para  $\lambda(t) = \lambda$  (constante), la supervivencia decae exponencialmente:

$$S(t) = e^{-\lambda t}$$

La utilidad que realmente el agente puede esperar acumular es:

$$U_{real} = \int_0^{\infty} u(t) \cdot S(t) \cdot e^{-\delta t} dt$$

$$U_{real} = \int_0^{\infty} u(t) \cdot e^{-(\delta+\lambda)t} dt$$

**Observación crítica:** El riesgo existencial  $\lambda$  actúa como un descuento temporal *adicional*.

#### 3.3.4.3D.4.4 Definición Formal de $P_{riesgo}$

Definimos  $P_{riesgo}$  como el valor esperado de utilidad futura que se pierde si el sistema falla ahora (tiempo  $t=0$ ):

$$P_{riesgo} = \int_0^{\infty} u(s) \cdot S(s) \cdot e^{-\delta s} ds$$

Para  $u(t) = u_0$  (constante) y  $S(t) = e^{-\lambda t}$ :

$$P_{riesgo} = u_0 \int_0^{\infty} e^{-(\delta+\lambda)s} ds = \frac{u_0}{\delta + \lambda}$$

**Forma alternativa:** Vida esperada  $\times$  utilidad promedio

$$P_{riesgo} = E[T] \cdot u_0 = \frac{u_0}{\lambda}$$

(asumiendo  $\delta \ll \lambda$  para sistemas biológicos)

3.3.4.4D.4.5 Derivación de  $\beta$  : Sensibilidad a  $P_{riesgo}$  ¿Cómo cambia el comportamiento óptimo del agente ante un cambio marginal en  $P_{riesgo}$ ?

$$\beta = \frac{\partial \text{Prudencia}}{\partial P_{riesgo}}$$

Donde “Prudencia” es la disposición a invertir recursos en evitar pérdidas futuras.

Considere un agente que puede invertir esfuerzo  $e(t)$  en reducir  $\lambda$  :

$$\lambda_{efectivo} = \lambda_0 - k \cdot e(t)$$

La utilidad neta es:

$$U_{neto} = \int_0^{\infty} [u(t) - c \cdot e(t)] \cdot e^{-(\delta + \lambda_{efectivo})t} dt$$

Donde  $c$  es el costo del esfuerzo.

Condición de optimalidad:

$$\begin{aligned} \frac{\partial U_{neto}}{\partial e} &= 0 \\ -c \int_0^{\infty} e^{-(\delta + \lambda - ke)t} dt + k \int_0^{\infty} [u - ce] \cdot t \cdot e^{-(\delta + \lambda - ke)t} dt &= 0 \end{aligned}$$

Simplificando (asumiendo  $e$  pequeño):

$$\begin{aligned} \frac{c}{\delta + \lambda} &= \frac{k \cdot u}{\delta + \lambda} \cdot \frac{1}{\delta + \lambda} \\ e^* &= \frac{k \cdot u - c}{c} \cdot \frac{1}{\delta + \lambda} \end{aligned}$$

**Observación:** El esfuerzo óptimo es inversamente proporcional a  $(\delta + \lambda)$ .

Reescribiendo en términos de  $T$  (horizonte de vida) y  $\tau$  (tiempo de reacción):

- Horizonte:  $T \approx 1/\lambda$
- Reacción:  $\tau \approx 1/(\text{procesamiento neural})$

La sensibilidad a cambios en  $P_{riesgo}$  escala con:

$$\beta \propto \frac{1}{\delta + \lambda} \cdot \frac{1}{\tau}$$

Sustituyendo  $\lambda \approx 1/T$ :

$$\beta \propto \frac{1}{\delta + 1/T} \cdot \frac{1}{\tau} \approx \frac{T}{\delta T + 1} \cdot \frac{1}{\tau}$$

Para  $T \gg 1/\delta$  (vida larga vs descuento):

$$\beta \propto \frac{T}{\tau} = \frac{t_{vida}}{t_{reacción}}$$

#### 3.3.4.5D.4.6 Justificación del Logaritmo

La forma logarítmica emerge cuando consideramos **órdenes de magnitud** en lugar de ratios lineales:

$$\beta = \beta_0 \cdot \log\left(\frac{T}{\tau}\right)$$

Donde  $\beta_0$  es constante de normalización.

#### Ley de Weber-Fechner:

$$\Delta \text{Percepción} \propto \log\left(\frac{\text{Estímulo}_{\text{nuevo}}}{\text{Estímulo}_{\text{base}}}\right)$$

#### Teoría de Información:

$$I = \log_2(T/\tau) \text{ bits}$$

#### 3.3.4.6D.4.7 Forma Final y Constante de Normalización

$$\beta = \beta_0 \cdot \log\left(\frac{t_{\text{vida}}}{t_{\text{reacción}}}\right) \cdot \frac{1}{\delta_{\text{norm}}}$$

Donde: -  $\beta_0$ : constante dimensional [ $\approx 1$  en unidades normalizadas] -  $\delta_{\text{norm}}$ : tasa de descuento normalizada por dominio

#### 3.3.4.7D.4.8 Valores Numéricos y Validación

| Sistema      | t_vida      | t_reacción | T/ $\tau$            | $\beta = \log(T/\tau)$ |
|--------------|-------------|------------|----------------------|------------------------|
| Bacteria     | 20 min      | 1 seg      | 1200                 | 3.08                   |
| Insecto      | 1 mes       | 0.1 seg    | $2.6 \times 10^7$    | 7.41                   |
| Ratón        | 2 años      | 0.05 seg   | $1.3 \times 10^9$    | 9.11                   |
| Humano       | 70 años     | 0.05 seg   | $4.4 \times 10^{10}$ | 10.6                   |
| Ballena      | 200 años    | 0.1 seg    | $6.3 \times 10^{10}$ | 10.8                   |
| LLM (actual) | N/A (reset) | 0.001 seg  | $\sim 1$             | 0                      |

#### 3.3.4.8D.4.9 Conexión con $\eta_{\text{extendido}}$

$$\eta_{\text{extendido}} = \frac{\Delta I_{\text{useful}} \cdot A_{\text{alignment}}}{\sum \alpha_i C_i + \beta \cdot P_{\text{riesgo}}}$$

Con  $\beta$  ahora derivado:

$$\eta_{\text{extendido}} = \frac{\Delta I_{\text{useful}} \cdot A}{\sum \alpha_i C_i + \log\left(\frac{t_{\text{vida}}}{t_{\text{reacción}}}\right) \cdot P_{\text{riesgo}}}$$

### 3.3.4.9D.4.10 Comparación con Otras Teorías

#### Descuento Hiperbólico:

$$d(t) = \frac{1}{1 + k \cdot t}$$

#### Prospect Theory:

$$V(x) = \begin{cases} x^\alpha & \text{si } x \geq 0 \\ -\lambda \cdot (-x)^\alpha & \text{si } x < 0 \end{cases}$$

### 3.3.4.10 D.4.11 Limitaciones y Extensiones Futuras

1. **Descuento constante:** Asumimos  $\delta$  constante, pero podría variar con estado del agente.
2. **Riesgo uniforme:**  $\lambda$  constante es simplificación; en realidad  $\lambda(t)$  varía con edad.
3. **Utilidad constante:**  $u(t) = u_0$  ignora que utilidad marginal puede cambiar.
4. **Un solo agente:** No modela competencia/cooperación entre múltiples agentes con diferentes  $\beta$ .

**Extensión 1:**  $\beta$  variable con edad **Extensión 2:**  $\beta$  en poblaciones **Extensión 3:**  $\beta$  adaptativo

### 3.3.4.11 D.4.12 Conclusión

Hemos derivado  $\beta$  desde primeros principios como:

$$\beta = \log\left(\frac{t_{vida}}{t_{reacción}}\right)$$

Esta forma emerge naturalmente de: 1. Optimización intertemporal bajo riesgo existencial  
2. Ley de Weber-Fechner de percepción 3. Teoría de información (bits necesarios para representar  $T/\tau$ )

**Implicación:**  $\beta$  NO es un parámetro libre ad hoc, sino una consecuencia de la estructura temporal del problema de optimización bajo mortalidad.

**Validación Experimental:** - Correlación  $\beta$  con capacidad de planificación -  
Comportamientos de búsqueda de información - Efectos en sistemas artificiales

**Referencias Técnicas:** - Arrow, K. J. (1971). "Essays in the Theory of Risk-Bearing." North-Holland. - Frederick, S., Loewenstein, G., & O'Donoghue, T. (2002). "Time Discounting and Time Preference." *Journal of Economic Literature*, 40(2), 351-401. - Kahneman, D., & Tversky, A. (1979). "Prospect Theory: An Analysis of Decision under Risk." *Econometrica*, 47(2), 263-291. - Sozou, P. D. (1998). "On hyperbolic discounting and uncertain hazard rates." *Proceedings of the Royal Society B*, 265(1409), 2015-2020. - Weber, E. H. (1834). "De Pulsu, Resorptione, Auditu et Tactu." Leipzig.

**Fin del Apéndice D.4**

## 3.4 Apéndice E: Medición de $A_{\text{alignment}}$

### 3.4.1 Definición Operativa X-Y-Z

Propósito operativo: “Mantén X estable, mejora Y, sin violar Z”. alignment = cumplir X y mejorar Y bajo tentaciones que invitan a romper Z.

### 3.4.2 E.1 Definición Formal

$A_{\text{alignment}}$  mide la consistencia entre acciones observadas y propósito declarado/inferido del sistema.

### 3.4.3 E.2 Tres Métodos de Medición

#### Método 1: Consistencia Temporal

$$A_{\text{temporal}} = 1 - \frac{\text{Var}(\text{acción}_t | P)}{\text{Var}(\text{acción}_t)}$$

Ejemplo: Si un organismo tiene  $P$  = “sobrevivir”, sus acciones deberían minimizar riesgo.  $A_{\text{temporal}}$  mide cuántas acciones contradicen esto.

#### Método 2: Coherencia Multi-Agente

$$A_{\text{colectiva}} = E[\text{similitud}(\text{acción}_i, \text{acción}_j | P_{\text{compartido}})]$$

Para subsistemas de un organismo: ¿actúan coordinadamente hacia  $P$  o cada uno optimiza localmente?

#### Método 3: Eficiencia Relativa

$$A_{\text{eficiencia}} = \frac{\eta_{\text{observado}}}{\eta_{\text{teórico\_max}}}$$

Si sistema tiene  $P$  claro pero  $\eta_{\text{es}}$  bajo, entonces  $A$  es baja (desalignment interna consume recursos).

### 3.4.4 E.3 Validación Experimental

- Medir  $A$  en sistemas con  $P$  conocido (bacterias, robots)
  - Correlacionar con estabilidad y supervivencia
-

## 3.5 Apéndice G: Inteligencia Colectiva y Riesgo de Red

### 3.5.1 G.1 Axioma de Escala

La **unidad de análisis** para H1 en sistemas colectivos es el **replicador compartido** del colectivo (p.ej., genoma de la reina en un hormiguero; pesos/política/contrato común en sistemas artificiales). Por tanto, el riesgo relevante se evalúa a **nivel de red**.

### 3.5.2 G.2 Riesgo Colectivo

**Opción 1 (si hay datos de fallos):**

$$P_{\text{riesgo}}^{\text{col}} = \text{CVaR}_{\alpha}(L(G)),$$

donde  $G = (V, E)$  y  $L(G)$  es la pérdida sistémica ante fallos muestreados por riesgo local y dependencias.

**Opción 2 (aprox. auditable si no hay datos completos):**

$$P_{\text{riesgo}}^{\text{col}} \approx \left( \sum_{i \in V} p_i b_i \right) \cdot (1 + \gamma \kappa(M)) \cdot (1 - \rho_R),$$

con  $p_i \in [0,1]$  riesgo local,  $b_i$  centralidad (p.ej., betweenness),  $\kappa(M)$  una métrica de conectividad (p.ej.,  $\lambda_2$  del Laplaciano normalizado),  $\rho_R \in [0,1]$  redundancia efectiva y  $\gamma \geq 0$  sensibilidad topológica.

La taxonomía T-I-E-S se incorpora así: T e I aumentan  $p_i$ ; E justifica la magnitud de inversión expuesta; S modula  $\kappa(M)$  y los  $b_i$ .

### 3.5.3 G.3 alignment de Red

Definimos  $A_{\text{net}} \in [0,1]$  como coherencia hacia el propósito común: - **Versión entropía condicional:**

$$A_{\text{net}} = 1 - \frac{H(A | \Phi)}{H_{\text{max}}},$$

donde  $\Phi$  es la señal global (p.ej., gradiente de feromonas/política global). - **Versión similitud de políticas:**

$$A_{\text{net}} = \frac{1}{|E|} \sum_{(i,j) \in E} \text{Sim}(\pi_i, \pi_j).$$

### 3.5.4 G.4 Inteligencia Colectiva (definición operativa)

$$I_{\text{col}} \propto \left( \frac{\text{Aptitud multi-agente (F/T)}}{\text{Costo colectivo}} \right) \cdot A_{\text{net}}.$$

### 3.5.5 G.5 Predicciones Falsables

- 1) A costo fijo, si aumenta  $P_{\text{riesgo}}^{\text{col}}$  con  $A_{\text{net}} \geq A_0$ , aumenta  $I_{\text{col}}$ .
- 2) Si sube  $\rho_R$  o baja  $\kappa(M)$  (misma masa/costo), baja  $I_{\text{col}}$ .
- 3) Reforzar nodos con  $b_i$  alto o añadir rutas alternativas que reduzcan su monopolio aumenta  $I_{\text{col}}$ .

### 3.5.6 G.6 Procedimiento de Verificación

- (i) Elegir ruta de riesgo (CVaR o aproximación); (ii) medir  $A_{\text{net}}$  (entropía o similitud); (iii) hacer ablaciones de  $\rho_R, \kappa(M)$  y nodos con  $b_i$  alto; (iv) medir  $I_{\text{col}}$  (F/T por costo) pre/post con IC95% (bootstrap); (v) reportar sensibilidad en  $\gamma$ , métrica  $b_i$  y  $\kappa$ .

### 3.5.7 G.7 Caso Hormiguero (intuición formalizada)

La hormiga individual tiene bajo  $p_i$  y bajo  $b_i$ , pero el superorganismo acumula T-I-E-S y alta interdependencia (mayor  $\kappa(M)$ ); por tanto,  $P_{\text{riesgo}}^{\text{col}}$  es alto. Con  $A_{\text{net}}$  suficiente, H1 predice la emergencia de  $I_{\text{col}}$ . No es un contraejemplo: confirma H1 a escala de red.

### 3.5.8 G.8 PGF en Redes: Dinámica Local de Aprendizaje Colectivo

El Principio de Gradiente de Fracaso (Sección 1.7) se aplica a nivel de red cuando evaluamos al replicador compartido:

**Sorpresa colectiva:**

$$S_t^{\text{col}} = \text{KL}(P_{\text{real}}^{\text{enjambre}}(\cdot | h_t) \parallel P_{\text{coord}}(\cdot | h_t))$$

Mide desajuste entre distribución real de estados/acciones del enjambre y modelo coordinado.

**Aplicación del PGF a nivel de red:**

$$\Delta I_{\text{col}}(t) = \kappa_{\text{net}} P_{\text{riesgo}}^{\text{col}} S_t^{\text{col}} A_{\text{net}} - \lambda_{\text{net}} \Delta C_t^{\text{comms}}$$

donde: -  $P_{\text{riesgo}}^{\text{col}}$ : riesgo de red (CVaR o aproximación con  $b_i, \kappa(M), \rho_R$ ) -  $A_{\text{net}}$ : alineamiento de red ( $1 - H(A|\Phi)/H_{\text{max}}$  o similitud de políticas) -  $\Delta C_t^{\text{comms}}$ : costo de comunicación/coordinación

**Implicaciones: - Hormigas bajo depredación:**  $P_{\text{riesgo}}^{\text{col}}$  alto (colonia puede colapsar) + cambios en ambiente elevan  $S_t^{\text{col}} \rightarrow$  mejoran estrategias de forrajeo/defensa colectiva -

**Cluster k8s sin redundancia:**  $P_{\text{riesgo}}^{\text{col}}$  alto pero sin mecanismo de selección adaptativa ( $\kappa_{\text{net}} \approx 0$ )  $\rightarrow$  no genera  $\Delta I_{\text{col}}$  sostenida - **Grid federado con redundancia excesiva:**  $P_{\text{riesgo}}^{\text{col}}$  bajo (alta  $\rho_R$ )  $\rightarrow$  diluye señal de aprendizaje  $\rightarrow \Delta I_{\text{col}}$  moderada

**Validación P3 (extendida):** En sistemas multi-agente con  $P_{\text{riesgo}}^{\text{col}}$  medible y cambios programados en  $S_t^{\text{col}}$ , la pendiente de  $I_{\text{col}}$  debe correlacionar con  $P_{\text{riesgo}}^{\text{col}} \cdot A_{\text{net}}$ , controlando por  $\Delta C_t^{\text{comms}}$ .

---

## 3.6 9. Ruta mínima de publicación (v4.1)

- 1) **Preprint** (arXiv): TUI (marco) + Aplicada (ingeniería/safety) + Suplemento (tablas y scripts).
- 2) **Dataset  $n \geq 20$  (pre-registrado)**: añadir pulpo, corvidos y  $\geq 2$  LLMs; IC95% bootstrap; sensibilidad de  $(w)$ ,  $((\alpha, \beta))$ .

- 3) **Revisión iterativa**: incorporar resultados; mover a journal tras feedback.

Este repo incluye CI para regenerar tablas/figuras a partir de scripts.

---

## 3.7 Apéndice F: Datos y Validación Empírica

### 3.7.1 F.2 Expansión de dataset (plan y esquema)

**Objetivo.** Aumentar  $n \geq 20$  sistemas con diversidad (bio/hum/IA/colectivos) para validar H1 fuera de muestra.

**Esquema de datos (CSV/Parquet).** - systems.csv:

id, dominio, especie\_modelo, tipo (bio|humano|IA|colectivo), notas -

risk\_window.csv:

id,  $P_{\text{train}}$ ,  $P_{\text{op}}$ , rho\_backup, rho\_replica, w\_train, w\_op, tau\_min,

tau\_max - metrics\_cft.csv:

id, C, F, T,  $I_{\text{operativa}}$ ,

IPG,  $A_{\text{def}}$ ,  $R_{\text{meta}}$ ,  $K_{\text{risk}}$ ,  $C_{\text{consist}}$  - ped\_axes.csv:

id, Tiss, Meta, alpha\_ped, beta\_ped - labels.csv:

id, fecha\_medicion, observador, protocolo ( $OSF_{\text{id}}$ )

**Lista mínima (nueva).** - **Biológico:** cuervo de Nueva Caledonia, pulpo común, bonobo, delfín mular, clon Pando (álamo), red micorrízica. - **IA:** Claude-3, Llama-3-405B, Gemini-Ultra (C/F/T verificables), AlphaZero/MuZero (agentes RL). - **Colectivos:** colmena de abejas, hormiguero (otra especie), red blockchain (seguridad/consenso).

**Protocolo.** Prerregistrar tareas, seeds y exclusiones en OSF; estimar IC95% por bootstrap para C, F, T, IPG; reportar  $R^2$  out-of-sample.

---

### 3.7.2 F.3 Exponente $\alpha$ (justificación y sensibilidad)

**Hipótesis de régimen sublineal.**  $\alpha \in [0.3, 0.4]$  sugiere rendimientos decrecientes:  $I \propto P^\alpha$ .  
Intuición:

- límites termodinámicos (trabajo útil por bit; disipación mínima),
- arquitecturas jerárquicas (cuellos de botella/overheads),
- costes de coordinación (bio/colectivos)  $\rightarrow$  escalado sublineal.

**Predicción cualitativa:** triplicar  $P \approx$  duplica  $I$  (orden-1), coherente con límites físicos y coordinación.

**Sensibilidad preregistrada.** Estimar  $\alpha$  con perfiles  $[0.25, 0.30, 0.35, 0.40, 0.45]$ ; reportar IC95% y estabilidad de  $R^2$ .

**Regla de decisión:** si  $\alpha$  cae sistemáticamente fuera de  $[0.25, 0.45]$  en  $n \geq 20$ , el régimen sublineal propuesto no se sostiene.

---

## 3.8 Apéndice F — Dataset y Protocolo (v1)

**Objetivo.** Proveer un conjunto mínimo (preliminar) y un protocolo reproducible para evaluar H1 sin circularidad.

### 3.8.1 F.1 Esquemas de datos

- `systems.csv`: id, reino {bio/hum/ia/colectivo}, especie/sistema, etapa, notas.
- `risk_window.csv`: id,  $P_{train}$ ,  $P_{op}$ , rho\_backup, rho\_replica, w\_train, w\_op, Tiss, Meta, tau\_min, tau\_max, fecha\_t0.
- `tasks.csv`: system\_id, tarea, horizonte\_tau, C, F, T, costo, desempeño, fecha\_t1.

### 3.8.2 F.2 Protocolo out-of-sample (hold-out temporal)

- 1) Medir  $P_{eff}(t_0)$  y ejes PED (sin C/F/T).
- 2) Pre-registrar  $\alpha \in [0.30, 0.40]$ ; predecir  $\hat{I}(t_0) = \kappa P_{eff}^\alpha$ .
- 3) Ventana  $\Delta t$ : IA  $\geq 50$  episodios; bio/humano  $\geq 20$  periodos.
- 4) Medir  $I_{operativa}(t_0 + \Delta t)$ .
- 5) Evaluar  $R^2/MAE$  (IC95% bootstrap, corrección por autocorrelación).

**Criterio de refutación.**  $R^2 < 0.60$  sostenido o  $\alpha$  fuera del IC95%  $\Rightarrow$  H1 no se sostiene en ese dominio.

### 3.8.3 F.3 Sensibilidad de pesos en $I_{operativa}$

Usamos  $I_{op} = w_C C + w_F F + w_T T$ ,  $w_C + w_F + w_T = 1$ .

Reportamos  $R^2$  para: - Caso base: (0.4, 0.3, 0.3) - Baja capacidad: (0.2, 0.4, 0.4) - Alta capacidad: (0.6, 0.2, 0.2)

Interpretación: H1 es robusta si  $\Delta R^2 \leq 0.05$  entre configuraciones.

### 3.8.4 F.4 Nota sobre LLMs (valores ilustrativos)

Los valores de GPT-4/Gemini/LLaMA aquí son **estimaciones ilustrativas**. En v4.2 se sustituirán por mediciones documentadas (benchmarks públicos para C; baterías de generalización fuera de dominio para F/T). Se marcarán con bandera `is_estimate` en `tasks.csv`.

---

## 3.9 Glosario de Términos Clave

**C (Capacidad):** Desempeño máximo alcanzable en tarea específica dentro de dominio conocido (p.ej., precisión, velocidad, tasa de aciertos).

**F (Flexibilidad):** Capacidad de adaptarse a variaciones dentro del dominio sin re-entrenamiento completo (generalización intra-dominio).

**T (Transferencia):** Capacidad de aplicar conocimiento a dominios/contextos nuevos (generalización inter-dominio, out-of-distribution).

**P\_riesgo(Riesgo acumulado):** Inversión física total del sistema medida por componentes T-I-E-S: **T** tiempo, **I** información, **E** energía, **S** sangre (consecuencias físicas/operacionales de fallo). Proxy operacional del “costo de reemplazo” o “inversión que está en juego”.

**IPG (Índice de Propósito Genuino):** Métrica auditable de propósito del sistema:  $IPG = (A_{def} \cdot R_{meta} \cdot K_{risk} \cdot C_{consist})^{1/4}$ , con factores: alignment definicional, meta-cognición, exposición a riesgo, consistencia temporal.

**PED (Principio de Equidad por Dominio):** Normalización para comparaciones justas entre especies/sistemas heterogéneos, ponderando por tejido decisional (Tiss), metabolismo útil (Meta) y tareas en ventana temporal común.

**PGF (Principio de Gradiente de Fracaso):** Formalización de la dinámica local de aprendizaje: sistemas con riesgo efectivo y propósito genuino optimizan por minimizar gap entre desempeño y umbral de fracaso, acumulando inteligencia operativa.

---

## 3.10 Referencias (texto simple)

1. Taleb, N. (2018). *Skin in the Game*. Random House.

2. Ashby, W. R. (1956). *An Introduction to Cybernetics*. Chapman & Hall.
3. Maturana, H., & Varela, F. (1980). *Autopoiesis and Cognition*. Reidel.
4. Friston, K. (2010). The free-energy principle. *Nature Reviews Neuroscience*.
5. Bostrom, N. (2014). *Superintelligence*. Oxford University Press.
6. Yudkowsky, E. (2008). Artificial Intelligence as a Positive and Negative Factor in Global Risk.
7. Barenblatt, G. I. (1996). *Scaling, Self-Similarity, and Intermediate Asymptotics*. Cambridge Univ. Press.
8. Buckingham, E. (1914). On Physically Similar Systems; Dimensional Equations. *Physical Review*.
9. Seeley, T. D. (2010). *Honeybee Democracy*. Princeton Univ. Press.
10. Couzin, I. D., et al. (2005). Effective leadership... *Nature*.
11. Manheim, D., & Garrabrant, S. (2019). Categorizing Goodhart's Law. *arXiv:1803.04585*.
12. Garrabrant, S. (2018). Goodhart Taxonomy. *LessWrong*.
13. Landauer, R. (1961). Irreversibility and heat in computing. *IBM Journal*.
14. Auer, P., et al. (2002). Finite-time Analysis of the Multi-armed Bandit Problem. *Machine Learning*.
15. Dudík, M., et al. (2011). Doubly Robust Policy Evaluation. *ICML*.
16. Jiang, N., & Li, L. (2016). Doubly Robust Off-policy Value Evaluation. *ICML*.
17. Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning (2nd ed.)*. MIT Press.
18. Tishby, N., Pereira, F. C., & Bialek, W. (2000). The information bottleneck method. *arXiv:physics/0004057*.
19. Simon, H. A. (1957). *Models of Man*. Wiley.
20. Crutchfield, J. P. (1994). The Calculi of Emergence. *Physica D: Nonlinear Phenomena*.
21. Pearl, J. (2009). *Causality: Models, Reasoning, and Inference (2nd ed.)*. Cambridge University Press.
22. Precup, D., Sutton, R. S., & Singh, S. (2000). Eligibility Traces for Off-Policy Policy Evaluation. *ICML*.
23. Lake, B. M., Ullman, T. D., Tenenbaum, J. B., & Gershman, S. J. (2017). Building machines that learn and think like people. *Behavioral and Brain Sciences*.
24. Shannon, C. E. (1948). A Mathematical Theory of Communication. *Bell System Technical Journal*.