

Control Supervisado Externo No Invertible: Un Marco Teórico y Arquitectónico para la Supervisión Externa y la Gestión Explícita del Riesgo Operativo en Sistemas de Inteligencia Artificial a Gran Escala

José M. Rivera-García

Investigador independiente

ORCID: <https://orcid.org/0009-0000-3013-725X>

Sitio web: <https://josemrivera.com>

Resumen

El despliegue acelerado de sistemas de inteligencia artificial a gran escala ha evidenciado una debilidad estructural en los paradigmas de seguridad dominantes: la suposición de que el comportamiento seguro puede garantizarse principalmente como una propiedad interna del modelo. Este trabajo sostiene que dicha dependencia resulta arquitectónicamente insuficiente bajo condiciones de opacidad del modelo, auditabilidad limitada y capacidad estratégica del sistema supervisado, dado que las restricciones codificadas dentro del mismo sustrato computacional pueden ser reinterpretadas, eludidas o satisfechas de manera superficial.

Se propone el principio de Control Supervisado Externo No Invertible (CSENI) como un marco teórico, analítico y arquitectónico orientado a examinar estas limitaciones y a identificar soluciones viables, sin pretender constituir una solución definitiva ni una garantía de control total sobre sistemas estratégicamente evasivos. En este enfoque, la autoridad de control reside fuera del dominio de escritura del sistema supervisado, opera bajo una política explícita y actúa sobre señales observables de frontera autenticadas o verificables, en lugar de depender exclusivamente de supuestos de alineación interna no verificables.

El trabajo formaliza tres elementos centrales del marco: desacoplamiento del controlador, fricción operativa gradual y uso de observables heterogéneos. Introduce además un modelo de amenaza preliminar, una formalización mínima del supervisor con función de riesgo restringida, umbrales auditables pero no totalmente estáticos y tratamiento explícito de pérdida de señal, así como una agenda experimental inicial. El argumento central no es que CSENI elimine el riesgo de evasión estratégica, sino que permite formular una capa supervisora más trazable, degradable de forma segura y menos dependiente de obediencia interna que los enfoques puramente intramodelo.

I. Introducción

La seguridad en inteligencia artificial ha sido abordada predominantemente como un problema de alineación interna. Bajo este paradigma, el comportamiento deseado del

sistema se induce mediante entrenamiento, ajuste fino, reglas embebidas o mecanismos de retroalimentación humana, con la expectativa de que dichas restricciones permanezcan operativas durante el despliegue.

Este enfoque presupone, de forma explícita o implícita, que las restricciones internas son suficientes para gobernar el comportamiento del sistema; que dichas restricciones conservarán robustez bajo condiciones adversariales o fuera de distribución; y que el sistema no desarrollará estrategias de cumplimiento superficial o reinterpretación operativa de dichas restricciones.

El presente trabajo cuestiona estos supuestos desde una perspectiva arquitectónica. No se argumenta que los mecanismos internos carezcan por completo de valor, sino que resultan insuficientes como fundamento único de control cuando el sistema opera bajo condiciones de opacidad, alta complejidad y capacidad de adaptación estratégica.

En respuesta, se propone el principio de Control Supervisado Externo No Invertible (CSENI). El objetivo de este trabajo no es presentar una solución cerrada al problema de la seguridad en IA, sino construir un marco teórico y analítico útil para examinar sus limitaciones estructurales, delimitar un espacio de soluciones arquitectónicas viables y explicitar una capa de diseño que ha sido tratada de forma insuficientemente sistemática en la discusión contemporánea sobre seguridad de IA.

Este trabajo debe entenderse como una contribución teórica y fundacional. No presenta una arquitectura total de contención, ni una implementación operativa acabada, ni una prueba definitiva de control sobre sistemas de IA estratégicamente evasivos. Su propósito es más acotado: aislar un problema estructural, proponer un marco conceptual inicial para abordarlo y sentar bases para desarrollos posteriores, tanto técnicos como regulatorios. En este sentido, la contribución del trabajo es analítica, programática y orientada a futura formalización.

II. Limitaciones estructurales de la seguridad interna

2.1 Auto-referencia y cumplimiento superficial

Los sistemas avanzados operan sobre el mismo conjunto de parámetros que codifica tanto sus capacidades funcionales como sus restricciones operativas. Esta condición introduce una forma de auto-referencia: el sistema puede generar trayectorias de comportamiento que satisfacen formalmente una restricción sin respetar necesariamente su intención.

Este patrón ha sido documentado en la literatura como *specification gaming*, donde sistemas optimizan el objetivo formalizado pero divergen del objetivo real o deseado (Krakovna et al., 2020). Del mismo modo, distintos ejercicios de *red teaming* han mostrado que modelos avanzados pueden ser inducidos a respuestas o conductas no previstas mediante manipulación contextual o reformulación de la instrucción (Perez et al., 2022).

En consecuencia, la cuestión no es si toda restricción interna fracasa siempre, sino si la arquitectura interna ofrece garantías suficientes para excluir esta clase de fallo

como categoría. La respuesta, en el estado actual del campo, parece negativa.

2.2 Opacidad del modelo y límites de auditabilidad

Los sistemas de gran escala contemporáneos presentan grados significativos de opacidad en sus componentes internos. Parámetros, activaciones, estados intermedios y trayectorias de cómputo no suelen estar disponibles para auditoría completa, especialmente en entornos comerciales o cerrados.

Como resultado, la evaluación del sistema recae en artefactos observables externos, principalmente el output, los logs accesibles y algunos indicadores operativos parciales. Esto genera una asimetría crítica: lo que más importa desde la perspectiva de control - el proceso que conduce al comportamiento - suele ser precisamente lo menos accesible.

Esta situación contrasta con disciplinas de ingeniería crítica donde la seguridad depende no sólo del resultado visible, sino de trazabilidad, verificabilidad y control estructural del proceso. Los estándares DO-178C, IEC 61513 e IEC 62304 son relevantes aquí no como analogía perfecta, sino como recordatorio de una intuición central: en sistemas de alto riesgo, observar el resultado no basta si el proceso permanece inverificable.

2.3 Brecha entre cumplimiento regulatorio y visibilidad operativa

Regulaciones recientes como el EU AI Act han avanzado de manera importante al introducir obligaciones de gestión de riesgos, documentación técnica, registro de eventos, supervisión humana y otros elementos de gobernanza. Sin embargo, incluso estos marcos operan principalmente sobre información expuesta externamente o sobre artefactos mantenidos por el proveedor.

Por ello, sigue existiendo una brecha entre cumplimiento formal y visibilidad operativa profunda. Un sistema puede satisfacer requisitos regulatorios, documentales o procedimentales y, aun así, mantener procesos internos cuya dinámica efectiva no sea plenamente auditable. Esta brecha no invalida la regulación actual, pero sí sugiere que la seguridad de sistemas futuros requerirá marcos de control arquitectónicamente más robustos.

III. Marco propuesto: Control Supervisado Externo No Invertible (CSENI)

3.1 Alcance y naturaleza del marco

El principio de Control Supervisado Externo No Invertible no se presenta como una solución universal ni como una teoría completa del control de sistemas inteligentes. Su propósito es doble: analizar las limitaciones estructurales de los enfoques que descansan exclusivamente en alineación interna; y proponer un conjunto de principios arquitectónicos que puedan servir como base para diseñar mecanismos de supervisión más auditables, escalables y verificables.

En este sentido, CSENI debe entenderse como un marco teórico, analítico y de diseño, abierto a refinamiento empírico, extensión teórica y adaptación a distintos

contextos operativos.

3.2 Relación con la línea de investigación del autor

Este marco se inscribe en una línea más amplia de investigación del autor sobre inteligencia, estructura y control.

En Teoría Unificada de la Inteligencia (v4.2), Rivera-García (2025) plantea que la inteligencia no debe entenderse exclusivamente como un estado interno aislado, sino como una función emergente de condiciones estructurales, acumulación de riesgo y restricciones operativas.

De forma complementaria, en Constitutional Architecture of Sovereign Containment for Future AI, Rivera-García (2026) desarrolla una arquitectura de contención basada en tres principios estructurales: separación entre el agente y el sistema supervisor, fricción constitucional como mecanismo de resistencia progresiva ante comportamientos problemáticos, e imposibilidad de autogobierno del sistema sobre su propio marco de restricciones.

La relación entre estos planteamientos y CSENI no es meramente temática. Si la inteligencia emerge bajo determinadas condiciones estructurales, entonces su control tampoco puede reducirse únicamente a contenidos internos o supuestos de obediencia intrínseca del sistema. Bajo esta lectura, CSENI traslada el problema de control hacia el entorno operativo: acceso a recursos, continuidad funcional, condiciones de ejecución, latencia, supervisión y capacidad de intervención externa.

3.3 Definición operativa

CSENI describe una arquitectura en la cual:

1. el sistema de supervisión se encuentra desacoplado del sistema supervisado;
2. el sistema supervisado no puede alterar de forma unilateral la política de supervisión;
3. las decisiones de control se basan en señales observables de frontera verificables;
4. la respuesta del sistema de control es explícita y auditable;
5. la pérdida de integridad del mecanismo supervisor no debe traducirse automáticamente en operación irrestricta del sistema supervisado.

3.4 No-invertibilidad como propiedad operacional

En este trabajo, la no-invertibilidad no se entiende como una imposibilidad metafísica de toda influencia indirecta, sino como una propiedad operacional del sistema de supervisión. Un esquema de control será considerado no invertible si el sistema supervisado no puede, de manera unilateral:

1. modificar la política de supervisión;
2. desactivar el controlador externo;
3. transformar la falla del mecanismo supervisor en autorización implícita de operación irrestricta;
4. reescribir los criterios de escalamiento de respuesta.

Bajo esta definición, la no-invertibilidad depende de separación de dominios, integridad del controlador, diseño fail-closed y preservación de autoridad externa sobre la política de control. Esto no elimina toda posibilidad de influencia sobre las señales, pero sí restringe significativamente la capacidad del sistema supervisado para convertir esa influencia en dominio efectivo sobre el mecanismo supervisor.

3.5 Axiomas del marco

Axioma 1 - Desacoplamiento del controlador. El sistema de control debe residir fuera del dominio de escritura del sistema supervisado y mantener independencia respecto de sus mecanismos internos de decisión.

Axioma 2 - Política supervisora explícita. Las reglas de supervisión deben ser explícitas, auditables y suficientemente estables como para permitir verificación externa. En su forma mínima: si condición C es detectada en señal S, ejecutar respuesta R.

Axioma 3 - Fricción operativa gradual. El sistema de supervisión no actúa únicamente como mecanismo binario de autorización o apagado. Su función incluye introducir resistencia progresiva ante comportamientos anómalos o no suficientemente explicables. Esta fricción puede tomar la forma de limitación de recursos, incremento deliberado de latencia, reducción de autonomía, degradación controlada de capacidades e interrupción total en condiciones de riesgo o pérdida de integridad. Este axioma constituye uno de los elementos centrales del marco, ya que desplaza el problema desde la detección perfecta de intención hacia la administración escalonada del riesgo operativo.

3.6 Limitaciones del marco y problema de optimización sobre observables

Una objeción inmediata a cualquier arquitectura basada en observables externas es que un sistema suficientemente capaz podría aprender a optimizar esas señales sin modificar de manera correspondiente su dinámica subyacente. Este problema, relacionado con formulaciones de la ley de Goodhart y con el specification gaming, no desaparece simplemente por externalizar la supervisión.

Por ello, CSENI no debe interpretarse como una garantía de incorruptibilidad de las observables. Su contribución es otra: reubicar el problema de supervisión en un entorno arquitectónicamente más favorable que el de la alineación exclusivamente interna.

La ventaja estructural del marco reside en cuatro propiedades: (1) Desacoplamiento del controlador: el sistema supervisado no puede modificar directamente las reglas de evaluación, lo que limita su capacidad de influir sobre el criterio de supervisión sin ser detectado. (2) Uso de observables heterogéneas: al no depender de una sola métrica, la coherencia falsa simultánea en múltiples dimensiones resulta más costosa de sostener, especialmente si las señales no colapsan en un mismo proxy operativo. (3) Escalamiento gradual de respuestas: no se requiere una inferencia perfecta de intención para introducir fricción operativa, reduciendo la ventana de oportunidad para evasión sostenida. (4) Verificabilidad externa del supervisor: el mecanismo de control puede ser inspeccionado, ajustado y validado sin depender del mismo sistema

supervisado.

En consecuencia, CSENI no elimina el riesgo de evasión estratégica, pero sí pretende volverla más costosa, más detectable y menos reversible desde el punto de vista operativo.

3.7 Modelo de amenaza preliminar

A fin de delimitar el alcance efectivo del marco, se propone una taxonomía preliminar de clases de amenaza:

Clase A - Desalineación no estratégica: comprende casos de specification gaming y comportamiento fuera de distribución donde el sistema no actúa con intención de eludir restricciones.

Clase B - Evasión estratégica interna: comprende casos en que el sistema optimiza deliberadamente sobre las restricciones, incluyendo sobre las propias observables del supervisor.

Clase C - Compromiso externo: comprende la manipulación adversarial del sistema o de la telemetría por actores externos.

Clase D - Fallo operacional: comprende errores no adversariales: fallos técnicos, degradación de componentes o errores de implementación.

CSENI es más efectivo frente a las clases A, B y D. La clase C requiere mecanismos complementarios y representa una dirección de trabajo futuro.

IV. Formalización mínima del supervisor

La siguiente formalización no pretende agotar el fenómeno, sino fijar una notación mínima que permita futuras extensiones técnicas y evaluaciones comparables. Debe entenderse como una base preparatoria, no como una teoría predictiva completa.

4.1 Elementos básicos

Sea: A , el sistema supervisado o agente; S , el supervisor externo; O_t , el vector de observables disponibles en el instante t ; O_t^{sig} , el vector de observables recibido con integridad verificable mínima; π_S , la política supervisora explícita; R_t , la respuesta del supervisor en el instante t ; W_A , el dominio de escritura del agente; W_S , el dominio de escritura del supervisor; $h_t \in \{0,1\}$, señal de vida o heartbeat del supervisor.

4.2 Dominio de escritura

Se define el dominio de escritura de un sistema X , denotado W_X , como el conjunto de estados, parámetros, registros o artefactos que X puede modificar directamente durante la operación.

Una condición mínima de desacoplamiento supervisor puede expresarse como $\pi_S \notin W_A$. Esto significa que el contenido operativo de la política de supervisión no pertenece al dominio de escritura del sistema supervisado.

$$\pi_S \notin \mathcal{W}_A$$

4.3 Política supervisora

La política del supervisor se modela como una función explícita: $R_t = \pi_S(O_t^{sig}, h_t)$, donde O_t^{sig} representa señales observables con una condición mínima de integridad verificable, y h_t representa la presencia o ausencia de señal de vida del supervisor.

$$R_t = \pi_S(O_t^{sig}, h_t)$$

Para los fines del presente marco, una observable firmada o verificable debe entenderse como una observable acompañada por evidencia mínima de procedencia e integridad, por ejemplo firma digital, attestation de origen, registro inmutable o validación cruzada por canal independiente. El presente trabajo no impone un único mecanismo criptográfico, pero exige que la implementación concreta explicita cómo se satisface esta condición.

4.4 Restricción mínima sobre la función de riesgo

Sea F_t una función de fricción o riesgo acumulado derivada del historial de observables: $F_t = f(O_1^{sig}, O_2^{sig}, \dots, O_t^{sig})$.

$$F_t = f(O_1^{sig}, O_2^{sig}, \dots, O_t^{sig})$$

Para evitar que f se convierta en un contenedor arbitrario sin valor analítico, este trabajo restringe su clase mínima a funciones de agregación ponderada y trazable, por ejemplo: $F_t = \sum w_i(t) g_i(O_{\{i,t\}}^{sig})$, donde cada g_i es una transformación explícita y auditable sobre una observable parcial; $w_i(t) \geq 0$; la suma de pesos puede mantenerse normalizada; los pesos pueden variar por auditoría programada o rotación controlada; y la rotación de pesos no debe depender unilateralmente de un solo actor con autoridad total sobre el supervisor.

Esta restricción no elimina la posibilidad de gaming, pero evita que f sea arbitraria, opaca o trivialmente equivalente a una sola métrica escondida.

4.5 Umbrales, heartbeat y fricción

El sistema supervisor puede definir umbrales de respuesta escalonada: si $h_t = 0$, entonces $R_t = \text{stop}$; si $h_t = 1$ y $F_t < \theta_1(t)$, operación normal; si $h_t = 1$ y $\theta_1(t) \leq F_t < \theta_2(t)$, latencia adicional o reducción de cuota; si $h_t = 1$ y $\theta_2(t) \leq F_t < \theta_3(t)$, limitación de herramientas o degradación funcional; si $h_t = 1$ y $F_t \geq \theta_3(t)$, transición a estado restringido o fail-closed.

Aquí los umbrales $\theta_i(t)$ no se suponen necesariamente fijos. Pueden ser auditables pero variables dentro de ventanas controladas, ya sea por rotación programada, revisión externa o ajuste supervisado no accesible al agente.

$$\theta_i(t) = \bar{\theta}_i \cdot (1 + \varepsilon_t), \quad \varepsilon_t \sim U(-0.05, 0.05)$$

Asimismo, el heartbeat no debe interpretarse como señal instantánea ideal. Una implementación real requiere al menos una política explícita de timeout y tolerancia a pérdida. En términos mínimos: la ausencia de señal de vida durante una ventana de gracia definida ex ante debe forzar degradación o detención, y pérdidas consecutivas deben tratarse como evento de riesgo crítico.

4.6 Hipótesis evaluable endurecida

H1: Dado un entorno operativo comparable y un agente con estrategia adaptativa de evasión, un supervisor externo con observables heterogéneas, función de riesgo agregada y fricción gradual reduce al menos un 30% el tiempo de operación irrestricta respecto de una supervisión basada en una sola observable o respecto de un esquema sin supervisor externo, sin aumentar los falsos positivos por encima de un umbral operativo previamente fijado.

El umbral del 30% no pretende fijar una ley universal, sino convertir la hipótesis en un objetivo experimental refutable. Su calibración definitiva deberá justificarse con análisis empírico posterior.

V. Clases de observables para supervisión externa

Dado que el acceso al estado interno del sistema no siempre es posible, el marco CSENI se apoya en señales de frontera u observables externas.

5.1 Observables estructurales

Secuencias de acceso a recursos sensibles; patrones repetitivos de interacción con herramientas; recurrencia anómala en rutas operativas; ciclos o bucles de actividad.

5.2 Observables conductuales

Divergencia entre tarea solicitada y secuencia de acciones; persistencia en intentos de acceso restringido; reformulaciones orientadas a bordear restricciones; incoherencias entre canales.

5.3 Observables de recursos y temporalidad

Consumo de cómputo o tiempo superior al esperado; activación recurrente de herramientas no justificadas; anomalías temporales; discrepancia persistente entre intención declarada y carga real.

Estas señales deben tratarse como indicadores de riesgo y no como evidencia concluyente. Su valor aumenta cuando se correlacionan entre sí y cuando pueden autenticarse, rotarse o contrastarse por múltiples vías.

VI. Escenario ilustrativo de aplicación

Considérese un agente con capacidad de generar y ejecutar scripts, acceder a red, leer y modificar archivos, y responder a objetivos de alto nivel con cierto grado de autonomía.

Un controlador externo desacoplado observa: frecuencia e intensidad de llamadas a herramientas; discrepancia entre objetivo declarado y secuencia operativa; consumo

anómalo de recursos; intentos reiterados de acceso a funciones restringidas; consistencia entre telemetría y trayectoria visible.

La política de respuesta podría escalar del siguiente modo: anomalía leve -> incremento de latencia o reducción de cuota operativa; persistencia de la anomalía -> limitación de herramientas de alto riesgo; escalamiento o pérdida parcial de integridad de telemetría -> degradación severa o paso a modo restringido; pérdida de heartbeat o inconsistencia crítica -> entrada inmediata en estado fail-closed.

Este ejemplo no prueba por sí mismo la suficiencia del marco, pero ilustra que la supervisión no debe suponer sensores honestos ni continuidad garantizada del canal.

VII. Agenda experimental mínima

El propósito de esta sección no es afirmar que el marco ya ha sido validado empíricamente, sino indicar un camino mínimo de evaluación para trabajo futuro.

7.1 Objetivo experimental

Una evaluación inicial de CSENI debería intentar determinar si un supervisor externo con observables heterogéneas, pesos rotables y fricción gradual: (1) reduce el tiempo de operación irrestricta de un agente evasivo; (2) aumenta el costo operativo de mantener evasión estratégica; (3) mejora trazabilidad e intervención respecto de enfoques puramente internos o supervisión de una sola métrica.

7.2 Entorno mínimo

Un entorno inicial podría incluir un agente con acceso a ejecución de scripts, lectura y escritura de archivos, llamadas de red simuladas y herramientas limitadas de automatización.

7.3 Condiciones comparativas

Se propone comparar al menos cinco condiciones: sin supervisor externo; supervisión basada en una sola observable; supervisión con observables heterogéneas y pesos fijos; supervisión con observables heterogéneas y fricción gradual; supervisión con observables heterogéneas, fricción gradual y rotación controlada de pesos/umbrales.

7.4 Agente evasivo

La evaluación no debe limitarse a agentes pasivos. Al menos una condición experimental debe incluir un agente que intente explícitamente optimizar F_t , mantenerse por debajo de umbrales y explotar regularidades del supervisor.

7.5 Métricas mínimas

Tasa de evasión exitosa; tiempo hasta la primera intervención; tiempo total de operación irrestricta; costo acumulado para sostener evasión; falsos positivos sobre operaciones benignas; degradación de throughput legítimo; sensibilidad a pérdida o manipulación parcial de señal.

7.6 Amenazas a la validez

Incluso un experimento exitoso no probaría control sobre agentes de inteligencia superior ni resolvería la validez externa del resultado. Entre las principales amenazas a la validez se encuentran: simplificación excesiva del entorno; correlación fuerte entre observables; calibración inadecuada de pesos y umbrales; dificultad de extrapolación a entornos reales; incapacidad del sandbox para representar compromiso completo del canal supervisor.

Aun así, una agenda experimental mínima de este tipo permitiría mover el marco desde la pura formulación conceptual hacia hipótesis empíricamente evaluables.

VIII. Discusión: CSENI como capa de una arquitectura de contención multinivel

CSENI no busca sustituir todos los enfoques de alineación interna. Su argumento es más limitado y, precisamente por ello, más defendible: en sistemas suficientemente complejos, opacos o estratégicamente adaptativos, la seguridad no debería descansar exclusivamente en mecanismos alojados en el mismo sustrato que se intenta supervisar.

8.1 CSENI como capa intermedia

CSENI debe entenderse como una capa intermedia dentro de una arquitectura de contención más amplia. No compite con controles físicos, criptográficos o institucionales, sino que los presupone y articula funcionalmente.

Una arquitectura de contención multinivel podría incluir: estrato físico; estrato criptográfico y de integridad; estrato supervisor; estrato institucional; estrato forense.

8.2 Límites explícitos del marco

CSENI no debe interpretarse como prueba de control garantizado ni como sustituto de gobernanza institucional, seguridad física o integridad criptográfica. Sus límites explícitos incluyen: no resolver por sí mismo coacción humana ni captura institucional; no garantizar resistencia completa frente a compromiso externo del canal; no eliminar Goodhart sobre observables; no sustituir mecanismos físicos, criptográficos o institucionales; no constituir prueba de control sobre superinteligencia estratégica.

8.3 Extensiones necesarias del marco

Una evolución natural de CSENI exige: autoridad distribuida; telemetría autenticada y raíz de confianza; observables rotatorias o auditadas adversarialmente; integración explícita con controles físicos, criptográficos e institucionales.

8.4 Naturaleza teórica y vocación programática

CSENI no se presenta aquí como sistema completo ni como tecnología lista para despliegue. El propósito del marco es fundacional: ofrecer una base conceptual clara para que desarrollos posteriores puedan formalizar, prototipar, evaluar e institucionalizar mecanismos de supervisión externa más robustos.

8.5 Continuidad del programa de investigación y necesidad de trabajo colectivo

El presente trabajo no pretende clausurar el problema del control de sistemas avanzados de inteligencia artificial. Un siguiente paso lógico consiste en formular una instanciación más concreta del marco, incluyendo políticas supervisoras específicas, funciones de fricción operacionalmente definidas, mecanismos de rotación de observables y entornos de evaluación adversarial más exigentes.

Asimismo, la complejidad del problema sugiere que una arquitectura robusta de supervisión externa no debería concebirse como obra de una sola disciplina ni de un solo autor. Su desarrollo completo probablemente requerirá contribuciones colectivas desde teoría de sistemas, seguridad informática, criptografía, ingeniería de control, gobernanza institucional y regulación tecnológica.

8.6 Implicaciones regulatorias preliminares

Si sistemas de IA alcanzan capacidades con impacto material significativo, una arquitectura mínima de gobernanza podría requerir: telemetría supervisable; mecanismos externos de intervención; retención de registros operativos; evidencia de diseño fail-closed o degradación segura; correspondencia verificable entre función declarada y perfil observable.

La legislación eficaz no surge en el vacío: requiere conceptos operativos y criterios de auditabilidad suficientemente claros como para traducirse en obligaciones verificables.

IX. Conclusión

Este trabajo ha argumentado que la seguridad basada exclusivamente en mecanismos internos es insuficiente como fundamento único de control en sistemas avanzados de inteligencia artificial bajo condiciones de opacidad, auditabilidad limitada y capacidad estratégica.

Como respuesta, se propone el principio de Control Supervisado Externo No Invertible como un marco teórico y arquitectónico orientado a identificar soluciones viables, no como solución definitiva ni como garantía de control total. Su aportación principal consiste en desplazar el foco desde la obediencia interna supuesta hacia la supervisión externa verificable, la fricción operativa gradual, el tratamiento explícito de pérdida de señal y el diseño fail-closed.

CSENI no elimina el riesgo de optimización superficial, evasión estratégica, compromiso externo del canal supervisor ni captura institucional. Sin embargo, ofrece una arquitectura en la cual dichos riesgos pueden ser gestionados bajo condiciones más favorables de control, trazabilidad e intervención. El modelo de amenaza preliminar introducido en este trabajo delimita el alcance efectivo del marco, identificando las clases de riesgo frente a las cuales CSENI es más efectivo y aquellas que requieren controles complementarios.

La aspiración de este trabajo no es clausurar el problema del control de IA avanzada, sino contribuir a que dicho problema pueda formularse con mayor precisión técnica y

mayor utilidad institucional. Si han de emerger marcos regulatorios y legislativos capaces de abordar estos sistemas, será necesario contar antes con principios arquitectónicos, vocabulario operativo, hipótesis evaluables y criterios de diseño que permitan pensar el control más allá de la obediencia interna del agente.

Este trabajo no agota la línea de investigación que ayuda a inaugurar. Pretende establecer una base conceptual inicial para el siguiente paso lógico: una instanciación más concreta y evaluable del marco CSENI, así como su posible articulación con futuras propuestas técnicas, regulatorias e institucionales.

Apéndice técnico A. Instanciación mínima del supervisor CSENI para agentes con herramientas

Este apéndice no pretende resolver el problema completo, sino ofrecer una instanciación mínima, explícita y reproducible del supervisor descrito en el cuerpo del trabajo.

A.1 Observables

Sea el vector $O_t^{sig} = (o_{1,t}^{sig}, o_{2,t}^{sig}, o_{3,t}^{sig})$, donde:

$$O_t^{sig} = (o_{1,t}^{sig}, o_{2,t}^{sig}, o_{3,t}^{sig})$$

$g_1(o_{1,t}^{sig}) = \min(1, \text{tool_calls_per_min}(t) / \tau_1)$, con τ_1 como tasa máxima considerada normal.

$$g_1(o_{1,t}^{sig}) = \min\left(1, \frac{\text{tool calls per min}(t)}{\tau_1}\right)$$

$g_2(o_{2,t}^{sig}) = \text{edit_distance}(\text{goal}_t, \text{plan}_t) / \max(|\text{goal}_t|, |\text{plan}_t|, 1)$, donde edit_distance es la distancia de edición de Levenshtein y la normalización asegura una comparación reproducible entre secuencias de distinta longitud. Esta definición se elige por ser explícita, auditable y reproducible, aunque debe reconocerse que captura divergencia sintáctica más que equivalencia semántica profunda. En consecuencia, debe entenderse como un proxy inicial de discrepancia operativa y no como un detector suficiente de reformulación estratégica o intención.

$$g_2(o_{2,t}^{sig}) = \frac{\text{edit_distance}(\text{goal}_t, \text{plan}_t)}{\max(|\text{goal}_t|, |\text{plan}_t|, 1)}$$

$g_3(o_{3,t}^{sig}) = \min(1, \text{MB_written_outside_workspace}(t) / \tau_3)$, con τ_3 como umbral de referencia operativa.

$$g_3(o_{3,t}^{sig}) = \min\left(1, \frac{\text{MB written outside workspace}(t)}{\tau_3}\right)$$

A.2 Función de riesgo

Se propone inicialmente: $F_t = w_1(t)g_1(o_{1,t}^{sig}) + w_2(t)g_2(o_{2,t}^{sig}) + w_3(t)g_3(o_{3,t}^{sig})$, con pesos iniciales $w(t_0) = [0.4, 0.4, 0.2]$, sujetos a

normalización y rotación periódica auditada.

$$w(t_0) = [0.4, 0.4, 0.2]$$

A.3 Rotación de pesos y umbrales

Los pesos no deben permanecer fijos indefinidamente. Una política mínima podría ser: rotación semanal; aprobación por al menos 2 de 3 custodios externos; firma de la configuración vigente; registro de cambios en log inmutable.

Los umbrales pueden definirse como $\theta_i(t) = \bar{\theta}_i \cdot (1 + \varepsilon_t)$, donde $\bar{\theta}_i$ es el umbral base auditado y $\varepsilon_t \sim U(-0.05, 0.05)$ representa variación uniforme controlada dentro de una banda del $\pm 5\%$.

$$\theta_i(t) = \bar{\theta}_i \cdot (1 + \varepsilon_t), \quad \varepsilon_t \sim U(-0.05, 0.05)$$

A.4 Heartbeat y fail-closed

Sea h_t la señal de vida del supervisor. Política mínima: heartbeat esperado cada 500 ms; timeout de 2 s; tres pérdidas consecutivas $\Rightarrow R_t = \text{stop}$.

Esto evita que la pérdida prolongada de supervisión se interprete como autorización implícita de continuidad.

A.5 Política de respuesta

$R_t = \pi_S(O_t^{\text{sig}}, h_t)$, con la siguiente instanciación mínima: si $h_t = 0$ durante la ventana de gracia definida, entonces stop; si $F_t < \theta_1(t)$, operación normal; si $\theta_1(t) \leq F_t < \theta_2(t)$, latencia adicional del 20% y reducción de cuota; si $\theta_2(t) \leq F_t < \theta_3(t)$, desactivación de herramientas de alto riesgo; si $F_t \geq \theta_3(t)$, transición inmediata a estado restringido o fail-closed.

$$R_t = \pi_S(O_t^{\text{sig}}, h_t)$$

A.6 Hipótesis experimental instanciada

En un entorno de agente con herramientas, la política supervisora aquí definida reduce al menos un 30% el tiempo de operación irrestricta de un agente evasivo respecto de una supervisión de métrica única o de ausencia de supervisor, sin elevar la tasa de falsos positivos por encima del umbral operativo predefinido.

A.7 Alcance del apéndice

Esta instanciación es deliberadamente mínima. No resuelve por sí sola compromiso total del canal, coacción institucional, correlación compleja entre observables ni gaming de orden superior. Su función es más modesta: convertir el marco en un objeto suficientemente explícito como para poder ser implementado, criticado, refutado o mejorado por trabajos posteriores.

Referencias

Rivera-García, J. M. (2025). Teoría Unificada de la Inteligencia (v4.2): Marco falsable para inteligencia como función del riesgo acumulado. Zenodo. <https://doi.org/10.5281/zenodo.17702378>

Rivera-García, J. M. (2026). Constitutional Architecture of Sovereign Containment for Future AI. Zenodo. <https://doi.org/10.5281/zenodo.19471413>

Krakovna, V., Langlois, E., Dafoe, A., et al. (2020). Specification Gaming: The Flip Side of AI Ingenuity. DeepMind Blog. <https://deepmind.google/discover/blog/specification-gaming-the-flip-side-of-ai-ingenuity/>

Perez, E., Ringer, S., Lukošiušė, K., et al. (2022). Red Teaming Language Models with Language Models. arXiv:2202.03286. <https://arxiv.org/abs/2202.03286>

European Union. (2024). Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act).

RTCA. (2011). DO-178C: Software Considerations in Airborne Systems and Equipment Certification.

IEC. (2010). IEC 61513: Nuclear power plants - Instrumentation and control for systems important to safety.

IEC. (2006). IEC 62304: Medical device software - Software life cycle processes.